

ECOLE D'INGENIERIE INFORMARTIQUE

CFA INGETIS

Département DATA ENGINEERING & IA

Année Académique 2025 - 2026

RAPPORT GESTION PROJET

Pour l'obtention du diplôme

Mastère 1 en Data Engineering & IA

Thème :

EcoTrack : Plateforme intelligente de gestion des déchets urbains

Présenté par :	Encadré par :
HOUNGBEME Mitondji Ferdinand	M. BOURGUIBA Abdelkarim
OUEDRAOGO Olivier	
ABDULMALAK Dany	

Soutenu le : 29 juin 2026

Table des matières

Liste des figures	4
Liste des tableaux	5
Chapitre 1 : Audit initial	6
Introduction	6
1. Contexte	6
2. Analyse SWOT	6
2.1. Forces	6
2.2. Faiblesses	6
2.3. Opportunités	7
2.4. Menaces	7
3. Identification des risques	7
4. Quick Wins	7
5. Recommandations stratégiques	8
Conclusion de l'audit initial	8
Chapitre 2 : Etude de faisabilité	9
1. Présentation générale du projet	9
1.1. Problématique	9
1.2. Objectifs	9
1.3. Enjeux de projet	10
2. Faisabilité technique	10
2.1. Architecture Data Lake	10
2.2. Pipeline de donnée	10
2.3. Base de données Analytique	11
2.4. Validation	11
3. Faisabilité économique	11
3.1. Ressources humaines (Coût 4 mois)	11
3.2. Infrastructure Cloud (4 mois de développement)	11
3.3. Licences et Outils	12
3.4. Coûts Récurrents (Années 2-3)	12
3.5. TCO (Total Cost of Ownership) sur 3 ans	13
3.5. Économie Estimées	13
3.6. Calcul du ROI	13
4. Faisabilité opérationnelle	13
Conclusion de faisabilité	14

Chapitre 3 : Veille Technologique	15
1. Méthodologie de veille technologique	15
2. Méthodologie de veille technologique	15
2.1 Traitement Batch : Apache Spark vs Dask vs Ray.....	15
2.2 Streaming : Apache Kafka vs RabbitMQ vs Pulsar	16
2.3 Outils d'orchestration ETL	16
2.4 Outils de transformation analytique	16
2.5 Outils de visualisation	17
2.6. Bases de données spatiales.....	18
2.7. Comparaison des frameworks Machine Learning.....	18
2.8. Choix d'une architecture OLAP	19
2.9. Contraintes légales et réglementaires	19
3. Tendances et innovations 2025.....	21
3.1 Data Lakehouse.....	21
3.2 Real-Time Analytics	21
3.3 Data Quality Observability	21
3.4 Edge Computing et IoT	22
3.5 Intelligence Artificielle Prédicative	22
4. Choix technologiques retenus pour ECOTRACK	22
5. Plan de veille continue	23
Conclusion de la veille technologique.....	23
Chapitre 4 : Architecture Data Lake & Pipelines.....	24
1. Architecture Data Lake	24
1.1. Bronze Layer : Données brutes.....	24
1.2. Silver Layer : Données nettoyées.....	25
1.3 Gold Layer : Données analytiques	25
2. Architecture des pipelines de données	26
2.1 Ingestion des données	26
2.2 Transformation des données.....	26
2.3 Orchestration des pipelines	26
2.4 Validation et qualité des données.....	26
3. Architecture de stockage	27
3.1 PostgreSQL et PostGIS	27
3.2 TimescaleDB	27
3.3 MinIO.....	27
4. Architecture analytique et visualisation.....	28
4.1 Power BI.....	28
4.2 Streamlit.....	28

4.3 API Analytics	28
5. Scalabilité et performances	29
5.1 Scalabilité horizontale	29
5.2 Optimisation des performances	29
5.3 Objectifs de performance.....	29
6. Sécurité et gouvernance des données	30
6.1 Sécurité des données	30
6.2 Gouvernance des données.....	30
Conclusion de l'architecture.....	31
Chapitre 5 : Modélisation des données	32
1. Objectifs de la modélisation	32
2. Approche de modélisation retenue	32
3. Modélisation conceptuelle des données (MCD)	32
4. Modélisation logique des données (MLD)	33
5. Modélisation physique des données (MPD).....	34
Conclusion de la modélisation	34
Chapitre 6 : Planification agile.....	35
1. Choix de la méthodologie Agile	35
2. Organisation de l'équipe projet	35
3. Framework Scrum adopté	36
4. Backlog produit	36
5. Organisation des sprints	37
6. Outils de gestion et collaboration	38
7. Indicateurs clés de performance (KPI)	38
8. Gestion des risques	39
9. Diagramme de Gantt.....	39
Conclusion de la planification Agile.....	40
Conclusion Générale.....	41
Bibliographie et Sitographie.....	42
Bibliographie.....	43

Liste des figures

Figure 1 : Architecture Data Lake	24
Figure 2 : MCD	33
Figure 3 : Diagramme de Gantt.....	40

Liste des tableaux

Tableau 1 : coût théorique d'un projet professionnel équivalent	11
Tableau 2 : Coûts d'infrastructure cloud sur 4 mois de développement.....	11
Tableau 3 : Coût des licences et outils	12
Tableau 4 : Coût d'infrastructure Production (par an).....	12
Tableau 5 : Coût de maintenance par an	12
Tableau 6 : Licence Récurrentes par an.....	13
Tableau 7 : Total Cost of Ownership	13
Tableau 8 : Économies annuelles attendues	13
Tableau 9 : Calcul détaillé.....	13
Tableau 10 : Comparaison Apache Spark vs Dask vs Ray	15
Tableau 11 : Comparaison Apache Kafka vs RabbitMQ vs Pulsar.....	16
Tableau 12 : Comparaison Apache Airflow vs Prefect vs Luigi	16
Tableau 13 : Comparaison dbt vs Talend vs Spark SQL	17
Tableau 14 : Power BI vs Apache Superset vs Metabase.....	17
Tableau 15 : Comparaison PostgreSQL/PostGIS vs MongoDB vs ClickHouse	18
Tableau 16 : Tableau comparatif.....	18
Tableau 18 : comparatif OLTP vs OLAP	19
Tableau 19 : Politique de rétention des données IoT	20
Tableau 20 : Objectifs de performance.....	30

Chapitre 1 : Audit initial

Introduction

L'audit initial constitue une étape essentielle dans la mise en œuvre du projet ECOTRACK. Il permet d'évaluer les besoins métiers, les contraintes techniques et les enjeux liés à la collecte, au stockage et à l'analyse des données issues des conteneurs connectés.

Dans le cadre d'un projet orienté Data Engineering & IA, cet audit vise principalement à analyser la capacité du système à gérer un volume important de données IoT, à garantir la qualité des données et à produire des indicateurs analytiques exploitables pour l'aide à la décision.

L'objectif est également d'identifier les risques liés aux pipelines de données, à la volumétrie, à l'historisation des mesures et aux traitements analytiques afin de concevoir une architecture data robuste, évolutive et adaptée aux besoins du projet ECOTRACK, intégrant une couche Machine Learning pour la prédiction et la détection d'anomalies.

1. Contexte

ECOTRACK est une plateforme intelligente de gestion des déchets urbains basée sur l'exploitation de données provenant de conteneurs connectés, de données opérationnelles et de mesures IoT historisées. Le projet vise à centraliser, transformer et valoriser les données afin de produire des indicateurs analytiques et des tableaux de bord décisionnels.

Le périmètre du projet couvre :

- l'ingestion des données IoT ;
- le stockage des données dans une architecture Data Lake ;
- la transformation des données via des pipelines ETL/ELT ;
- l'analyse des données spatiales et temporelles ;
- la production de dashboards analytiques ;
- la mise en place de modèles prédictifs liés au remplissage des conteneurs.

Le projet doit gérer une volumétrie importante avec environ 2000 conteneurs connectés et jusqu'à 180 millions de mesures par an. Cette volumétrie nécessite une architecture capable d'assurer la scalabilité, la qualité des données et de bonnes performances analytiques.

2. Analyse SWOT

2.1. Forces

Le projet ECOTRACK possède plusieurs atouts dans sa dimension data :

- architecture Data Lake structurée en couches Bronze, Silver et Gold ;
- utilisation de PostgreSQL/PostGIS pour les traitements analytiques et géospatiaux ;
- mise en place de pipelines ELT avec Airflow et dbt ;
- utilisation de TimescaleDB pour la gestion des séries temporelles ;
- forte orientation analytique et décisionnelle ;
- possibilité d'intégrer des modèles d'intelligence artificielle prédictive.

2.2. Faiblesses

Certaines contraintes techniques ont également été identifiées :

- forte volumétrie des données IoT ;
- complexité du traitement temps réel ;

- dépendance à la qualité des données collectées ;
- maîtrise partielle de certaines technologies avancées ;
- risque de latence sur les pipelines analytiques ;
- complexité des traitements géospatiaux.

2.3. Opportunités

Le projet offre plusieurs perspectives d'évolution :

- optimisation intelligente des tournées de collecte ;
- réduction des coûts opérationnels ;
- amélioration des indicateurs environnementaux ;
- développement futur de modèles prédictifs ;
- intégration dans des projets Smart City ;
- valorisation des données analytiques auprès des collectivités.

2.4. Menaces

Plusieurs risques externes peuvent affecter le projet :

- indisponibilité ou défaillance des capteurs IoT ;
- augmentation des coûts cloud et stockage ;
- problèmes de qualité ou de perte de données ;
- évolution des contraintes réglementaires ;
- dépendance à certains outils ou technologies.

3. Identification des risques

Risque	Probabilité	Impact	Criticité	Mitigation
Perte de données	Faible	Critique	Élevée	Sauvegardes automatisées et réplication
Qualité données <95%	Moyenne	Moyen	Moyenne	Validation Great Expectations + Pydantic
Latence pipeline >2s	Moyenne	Moyen	Moyenne	Optimisation Spark et cache Redis
Saturation stockage	Moyenne	Élevé	Élevée	Partitionnement et archivage MinIO
Échec pipeline ELT	Moyenne	Élevé	Élevée	Monitoring Airflow et alertes
Mauvaises performances analytiques	Moyenne	Moyen	Moyenne	Agrégats pré-calculés et indexation
Dépassement budget cloud	Moyenne	Moyen	Moyenne	Supervision consommation ressources

4. Quick Wins

Action	Effort	Impact	Bénéfice
Validation qualité des données	4h	Élevé	Réduction erreurs pipelines
Partitionnement TimescaleDB	1 jour	Élevé	Requêtes plus rapides
Mise en place Airflow monitoring	4h	Moyen	Détection rapide erreurs
Agrégats pré-calculés	1 jour	Élevé	Dashboards temps réel

5. Recommandations stratégiques

Afin d'assurer la réussite du projet ECOTRACK, plusieurs recommandations stratégiques sont proposées :

- mettre en place une architecture Data Lake évolutive ;
- automatiser les contrôles qualité des données ;
- privilégier les formats analytiques optimisés (Parquet) ;
- assurer une historisation complète des mesures IoT ;
- mettre en œuvre un monitoring permanent des pipelines ;
- anticiper l'intégration future de modèles de Machine Learning ;
- optimiser les traitements géospatiaux avec PostGIS et TimescaleDB.

Conclusion de l'audit initial

L'audit initial montre que le projet ECOTRACK présente une faisabilité favorable dans sa dimension Data Engineering & Analytics. Les technologies retenues permettent de répondre aux besoins de collecte, de transformation et d'analyse des données à grande échelle.

L'architecture envisagée, combinant Data Lake, pipelines ETL, PostgreSQL/PostGIS et outils analytiques, constitue une base cohérente pour la mise en œuvre d'une plateforme décisionnelle orientée données.

Les risques identifiés restent maîtrisables grâce à l'automatisation des traitements, à la supervision des pipelines et à la mise en œuvre de mécanismes de validation des données. Le projet démontre également sa capacité à intégrer des usages avancés d'analyse prédictive avec des modèles ML déployés et d'optimisation intelligente des tournées de collecte.

Au regard des éléments étudiés, le lancement du projet ECOTRACK est considéré comme favorable dans une perspective Data Engineering & IA.

Chapitre 2 : Etude de faisabilité

1. Présentation générale du projet

ECOTRACK est une plateforme intelligente de gestion des déchets urbains reposant sur l'exploitation de données issues de conteneurs connectés, de fichiers historiques et de données opérationnelles de collecte. L'objectif du projet est de concevoir une architecture capable de centraliser, fiabiliser, transformer et valoriser ces données afin de produire des indicateurs utiles et à la décision. Le périmètre couvre la gestion de conteneurs, l'analyse des niveaux de remplissage, le suivi géographique des zones, l'historisation des mesures, d'aide à l'optimisation des tournées, conception des modèles et la mise à disposition de tableaux de bord analytiques.

Dans le cadre pédagogique ECOTRACK, la volumétrie visée est significative : environ **2000 conteneurs connectés, 500 000 mesures par jour** et jusqu'à **180 millions de mesures par an**. Cette volumétrie impose une réflexion sérieuse sur l'ingestion, le stockage, le partitionnement, les performances de requête et la préparation des données pour l'analyse. La plateforme doit également gérer une forte dimension géographique, car les conteneurs, les zones de collecte et les tournées sont localisés dans l'espace et doivent pouvoir être analysés sur des cartes ou via des requêtes spatiales. Le projet intègre donc naturellement **PostgreSQL + PostGIS** pour la donnée géospatiale, ainsi qu'une logique d'entrepôt de données orientée décisionnel.

Le projet ECOTRACK s'inscrit donc dans une logique de **data-driven management**, où les décisions opérationnelles reposent sur l'analyse des données collectées.

1.1. Problématique

La gestion traditionnelle des déchets repose souvent sur des tournées fixes, planifiées indépendamment de l'état réel des conteneurs. Cette approche génère plusieurs inefficacités :

- absence de visibilité en temps réel sur le niveau de remplissage des conteneurs
- tournées de collecte parfois inutiles ou mal optimisées
- débordements fréquents de conteneurs dans certaines zones
- coûts élevés liés au carburant, à la main-d'œuvre et à la maintenance
- difficulté à analyser les performances du système de collecte
- émission de CO₂, pollution

1.2. Objectifs

Le projet ECOTRACK vise à améliorer la gestion des déchets urbains grâce à l'exploitation des données collectées. Les principaux objectifs sont :

- centraliser les données issues des capteurs IoT et des sources opérationnelles
- stocker et structurer ces données dans une base analytique adaptée
- analyser l'évolution du taux de remplissage des conteneurs
- identifier les zones géographiques nécessitant une attention particulière
- Fournir des **tableaux de bord interactifs** pour les gestionnaires
- permettre l'analyse historique des performances du système de collecte
- développer un **modèle prédictif** permettant d'anticiper le remplissage des conteneurs
- réduire les coûts de collecte de 20-30%

- éliminer les débordements (<5% incidents)
- optimiser les tournées

1.3. Enjeux de projet

La couche data du projet ECOTRACK doit répondre à plusieurs défis techniques et analytiques :

- gestion d'un volume important de données provenant des capteurs
- traitement et transformation des données via un pipeline ETL
- stockage efficace des données dans une base PostgreSQL avec extension géospatiale PostGIS
- préparation des données pour l'analyse et la visualisation
- production d'indicateurs clés (KPI) pour le pilotage opérationnel
- mise en place d'analyses spatiales et temporelles des données
- développement de modèles prédictifs pour anticiper le remplissage des conteneurs
- détection automatique des anomalies capteurs via apprentissage non supervisé

Ces enjeux nécessitent la conception d'une architecture data robuste, capable de collecter, transformer, stocker, valoriser les données et déployer des modèles intelligents afin de produire des analyses pertinentes et exploitables par les décideurs.

2. Faisabilité technique

L'architecture Data retenue pour ECOTRACK repose sur une chaîne de traitement structurée permettant de collecter, transformer, stocker et analyser les données issues des conteneurs connectés et des fichiers historiques, tout en intégrant une couche Machine Learning pour la prédiction du remplissage et la détection d'anomalies. L'objectif est de disposer d'une architecture simple, cohérente au regard du périmètre du projet, tout en restant évolutive.

2.1. Architecture Data Lake

- **Stockage** : MinIO, est compatible S3, scalable sécurisé, Grâce à sa compatibilité S3, son contrôle d'accès IAM, le chiffrement, le versioning et l'object locking, MinIO apporte une base solide pour construire une architecture data propre, traçable et sécurisée.
- **Bronze Layer** : données brutes Parquet/JSON (données IOT), CSV (pour les données opérationnelles).
- **Sliver Layer** : données nettoyées + validation qualité
- **Gold Layer** : données prêtes pour les dashboards et ML

2.2. Pipeline de donnée

- **Ingestion des données** : **Python**, il est utilisé pour l'ingestion et les traitements spécifiques, car il est flexible, simple à intégrer avec les API, fichiers et bases de données.
- **Transformation** : **dbt**, est utilisé pour transformer les données de manière structurée, versionnée et maintenable avec du SQL. Il facilite la maintenance et l'évolution du modèle de données.
- **Orchestration** : **Airflow**, utilisé pour orchestrer les pipelines, planifier les tâches, gérer les dépendances et suivre les erreurs.

- **Validation : dbt tests** pour contrôler la qualité des données transformées avant exposition dans Power BI et ML, et **Pydantic / Great Expectations** pour contrôler la qualité des données.
- **Conteneurisation** : Docker
- **Versioning** : GitHub

2.3. Base de données Analytique

- **PostgreSQL** pour stocker les données structurées
- **PostGIS** pour gérer les données géospatiales
- **TimescaleDB** si tu as beaucoup de mesures temporelles
- **Tables analytiques** pour exposer des données propres aux dashboards
- **Vue ML (VW_ML_DATASET)** pour préparer les données aux modèles prédictifs
- **Rétention** : données brutes dans MinIO (bucket archive) · données agrégées en base PostgreSQL.

2.4. Validation

- **BI (Power bi)** : pour analyser les indicateurs métier et produire des tableaux de bord décisionnels.
- **Streamlit** : pour développer rapidement des interfaces analytiques et des applications de visualisation des résultats ML.
- **Rapports** : pour documenter les analyses, les résultats analytiques et les performances des modèles ML.
- **Data Mart Analytique** : dbt pour exposer les données transformées et structurées aux outils de visualisation

3. Faisabilité économique

3.1. Ressources humaines (Coût 4 mois)

Tableau 1 : coût théorique d'un projet professionnel équivalent

Poste	Charge	Coût estimé
Product Owner	25 %	12 k€
Scrum Master	25 %	10 k€
Développeurs / Experts (3 personnes)	100 %	108 k€
Architecte Data	50 %	18 k€
DevOps / SRE	50 %	16 k€
Sous-Total RH		164 k€

3.2. Infrastructure Cloud (4 mois de développement)

Architecture réellement utilisée : VPS Contabo + Docker + PostgreSQL + PostGIS + MinIO + Airflow + dbt + Power BI + Streamlit Cloud

Tableau 2 : Coûts d'infrastructure cloud sur 4 mois de développement

Infrastructure	Description	Coût
----------------	-------------	------

VPS Contabo	Hébergement principal	1,2 k€
PostgreSQL + PostGIS	Base analytique	1,5 k€
MinIO	Stockage objet	0,8 k€
Apache Airflow	Orchestration pipelines	0,7 k€
Docker + supervision	Déploiement & monitoring	0,6 k€
Sauvegardes + réseau	Backup & bande passante	0,7 k€
Sous-Total Infrastructure		5,5 k€

3.3. Licences et Outils

Tableau 3 : Coût des licences et outils

Outil	Coût
GitHub (académique)	0 k€
Power BI Desktop	0 k€
Power BI Service	0,8 k€
Google Colab (Développement ML)	0 k€
Streamlit Cloud (Déploiement dashboard ML)	0 k
Monitoring	1,2 k€
Outils divers (IDE, design, etc.)	1,5 k€
SOUS-TOTAL Licences	3,5 k€

3.4. Coûts Récurrents (Années 2-3)

3.4.1. Infrastructure Production (par an)

Tableau 4 : Coût d'infrastructure Production (par an)

Infrastructure	Coût annuel
VPS Contabo (prod + staging)	12 k€
PostgreSQL + PostGIS	6 k€
MinIO + stockage	4 k€
Airflow + monitoring	5 k€
Backups & sécurité	5 k€
SOUS-TOTAL Infrastructure	32 k€/an

3.4.2 Maintenance et Support (par an)

Tableau 5 : Coût de maintenance par an

Poste	Coût annuel
Support (2 personnes à 50%)	52 k€
Évolutions fonctionnelles	12 k€
Corrections bugs	8 k€
Sécurité & mises à jour	6 k€
SOUS-TOTAL Maintenance	78 k€

3.4.3. Licences Récurrentes (par an)

Tableau 6 : Licence Récurrentes par an

Outil	Coût annuel
Monitoring / alerting	3 k€
Licences SaaS	2 k€
Sous-Total Licences	5 k€

TOTAL PAR AN (Années 2–3) : 115 k€/an

3.5. TCO (Total Cost of Ownership) sur 3 ans

Tableau 7 : Total Cost of Ownership

Année	Coût
Année 1 (Développement)	173 k€
Année 2 (Production)	115 k€
Année 3 (Production)	115 k€
TCO 3 ANS	403 k€

3.5. Économie Estimées

Tableau 8 : Économies annuelles attendues

Source d'économie	Gain annuel
Optimisation tournées (carburant -20%)	110 k€
Réduction débordements (-95%)	65 k€
Gains productivité	160 k€
Amélioration image / plaintes	25 k€
TOTAL ÉCONOMIES	360 k€/an

3.6. Calcul du ROI

Formule : $ROI = (\text{Gains cumulés} - \text{Investissement}) / \text{Investissement} \times 100$

Tableau 9 : Calcul détaillé

Élément	Valeur
Investissement initial	173 k€
Économies sur 3 ans	1 080 k€
Coûts récurrents (2 ans)	230 k€
Gain net	850 k€

ROI SUR 3 ANS : 391 %

Seuil de rentabilité : 1,2 an

4. Faisabilité opérationnelle

Le projet ECOTRACK repose sur une organisation Agile adaptée aux projets Data Engineering et Analytics. L'équipe projet est composée de plusieurs profils complémentaires incluant Product Owner, Data Engineers, Architecte Data et DevOps/SRE.

L'utilisation de la méthodologie Scrum permet :

- une livraison progressive des composants ;
- une meilleure gestion des priorités ;
- une adaptation continue aux besoins métier ;
- un suivi régulier de l'avancement du projet.

L'organisation en sprints facilite également la validation progressive des pipelines de données, des traitements analytiques, des modèles Machine Learning prédictifs et des dashboards décisionnels.

Les principaux risques opérationnels identifiés concernent :

- les retards de développement ;
- les problèmes de qualité des données ;
- les coûts d'infrastructure ;
- la complexité des intégrations techniques.

Toutefois, l'utilisation d'outils de supervision, de monitoring et de gestion de versions permet de limiter significativement ces risques.

Conclusion de faisabilité

L'étude de faisabilité du projet ECOTRACK met en évidence des conditions favorables de réalisation sur les plans technique, économique et opérationnel.

Les technologies retenues sont cohérentes avec les besoins du projet et permettent de répondre efficacement aux contraintes liées à la volumétrie des données, aux traitements analytiques, aux analyses géospatiales et au déploiement de modèles prédictifs Machine Learning.

L'analyse économique montre un retour sur investissement favorable ainsi qu'un potentiel important de réduction des coûts opérationnels.

Enfin, l'organisation Agile du projet et l'utilisation d'outils modernes de Data Engineering renforcent la capacité du projet à évoluer progressivement tout en maintenant une bonne maîtrise des risques identifiés.

Chapitre 3 : Veille Technologique

1. Méthodologie de veille technologique

La veille technologique réalisée dans le cadre du projet ECOTRACK a pour objectif d'identifier les technologies les plus adaptées aux besoins d'une plateforme orientée Data Engineering, IoT et analytique décisionnelle et Machine Learning prédictif. Cette veille permet d'évaluer les solutions disponibles selon plusieurs critères tels que les performances, la scalabilité, la compatibilité avec les traitements analytiques, la facilité d'intégration et les coûts d'exploitation.

La méthodologie adoptée repose sur une veille continue combinant plusieurs sources techniques et communautaires. Les principales sources consultées sont :

- documentations officielles ;
- GitHub ;
- Stack Overflow ;
- conférences spécialisées Data et Cloud ;
- retours d'expérience communautaires.

Les technologies ont été comparées selon :

- leurs performances ;
- leur capacité à gérer de fortes volumétries ;
- leur compatibilité avec les pipelines de données ;
- leur intégration avec les outils analytiques ;
- leur maturité et leur communauté.

Cette veille a permis de sélectionner un stack cohérent avec les objectifs techniques et analytiques du projet ECOTRACK.

2. Méthodologie de veille technologique

2.1 Traitement Batch : Apache Spark vs Dask vs Ray

Dans le cadre du projet ECOTRACK, plusieurs frameworks de traitement distribué ont été étudiés afin de choisir la solution la plus adaptée aux traitements analytiques et aux volumes de données générés par les conteneurs IoT.

Tableau 10 : Comparaison Apache Spark vs Dask vs Ray

Critère	Apache Spark	Dask	Ray
Performance	9/10	7/10	8/10
Scalabilité	9/10	7/10	8/10
Écosystème	10/10	6/10	7/10
Intégration Data	9/10	7/10	7/10
Déploiement	7/10	8/10	7/10
TOTAL	44/50	35/50	37/50

Apache Spark a été retenu grâce à :

- son écosystème mature ;
- sa forte capacité de traitement distribué ;
- son intégration avec Kafka, Airflow et les formats analytiques ;
- ses performances sur les traitements batch et streaming.

2.2 Streaming : Apache Kafka vs RabbitMQ vs Pulsar

Le projet ECOTRACK nécessite un système capable de gérer l'ingestion continue des données IoT avec une faible latence.

Tableau 11 : Comparaison Apache Kafka vs RabbitMQ vs Pulsar

Critère	Kafka	RabbitMQ	Pulsar
Débit	10/10	7/10	9/10
Scalabilité	9/10	7/10	9/10
Durabilité	9/10	8/10	9/10
Complexité	7/10	9/10	6/10
Écosystème	10/10	8/10	7/10
TOTAL	45/50	39/50	40/50

Apache Kafka a été retenu pour :

- sa capacité à gérer de gros volumes de données ;
- ses performances en temps réel ;
- son intégration avec Spark et les pipelines analytiques ;
- sa forte adoption dans les architectures Data Engineering.

2.3 Outils d'orchestration ETL

Apache Airflow vs Prefect vs Luigi

Les pipelines de données du projet nécessitent un orchestrateur capable de gérer les dépendances, les planifications et la supervision des traitements.

Tableau 12 : Comparaison Apache Airflow vs Prefect vs Luigi

Critère	Airflow	Prefect	Luigi
Gestion DAGs	10/10	8/10	7/10
Monitoring	9/10	8/10	6/10
Écosystème	10/10	7/10	6/10
Scalabilité	9/10	7/10	6/10
Simplicité	7/10	9/10	7/10
TOTAL	45/50	39/50	32/50

Apache Airflow a été retenu grâce à :

- sa large adoption dans le domaine Data Engineering ;
- sa gestion avancée des DAGs ;
- son intégration avec Spark, dbt et PostgreSQL ;
- ses fonctionnalités de monitoring et d'alerting.

2.4 Outils de transformation analytique

dbt vs Talend vs Spark SQL

Les traitements analytiques nécessitent une solution permettant de transformer les données de manière maintenable et versionnée.

Tableau 13 : Comparaison dbt vs Talend vs Spark SQL

Critère	dbt	Talend	Spark SQL
Simplicité SQL	10/10	6/10	8/10
Versioning	10/10	6/10	7/10
Maintenance	9/10	7/10	7/10
Documentation	10/10	7/10	6/10
Intégration Data Warehouse	9/10	8/10	7/10
TOTAL	48/50	34/50	35/50

dbt a été retenu pour :

- sa simplicité basée sur SQL ;
- son système de versioning ;
- sa documentation automatique ;
- sa forte intégration avec les architectures analytiques modernes.

2.5 Outils de visualisation

Power BI vs Apache Superset vs Metabase

Le projet nécessite des tableaux de bord analytiques pour le suivi des indicateurs métier et techniques.

Tableau 14 : Power BI vs Apache Superset vs Metabase

Critère	Power BI	Superset	Metabase
Visualisations	10/10	8/10	7/10
Connecteurs	9/10	8/10	8/10
Simplicité	9/10	7/10	9/10
Performance	9/10	8/10	7/10
Coût	7/10	10/10	10/10
TOTAL	44/50	41/50	41/50

Power BI a été retenu grâce à :

- ses capacités avancées de visualisation ;
- son intégration analytique ;
- sa simplicité de création de dashboards ;
- sa forte adoption en environnement décisionnel.

Streamlit vs Dash vs Gradio

Le projet nécessite également une interface dédiée à la visualisation des résultats Machine Learning et au déploiement du dashboard prédictif.

Tableau 14b : Streamlit vs Dash vs Gradio

Critère	Streamlit	Dash	Gradio
Intégration Python/ML	10/10	8/10	7/10
Déploiement cloud	10/10	8/10	8/10
Simplicité développement	10/10	7/10	9/10
Connexion base de données	9/10	8/10	7/10
Visualisations interactives	9/10	10/10	10/10
TOTAL	48/50	39/50	39/50

Streamlit a été retenu pour :

- sa flexibilité Python permettant une intégration directe avec les modèles XGBoost et Isolation Forest
- sa connexion native à PostgreSQL via psycopg2
- son déploiement gratuit sur Streamlit Cloud
- sa simplicité de développement d'interfaces analytiques interactives

2.6. Bases de données spatiales

Le benchmark des bases de données spatiales a été complété par l'ajout de MySQL Spatial afin d'élargir la comparaison des solutions relationnelles compatibles SIG.

Tableau 15 : Comparaison PostgreSQL/PostGIS vs MongoDB vs ClickHouse

Critères	Pondération	PostgreSQL/PostGIS	MySQL Spatial	MongoDB
Support spatial avancé	25%	5/5	3/5	2/5
Fonctions géographiques	20%	5/5	3/5	2/5
Compatibilité SIG	15%	5/5	3/5	2/5
Performance analytique	15%	5/5	4/5	3/5
Intégration Python	10%	5/5	4/5	4/5
Documentation & communauté	10%	5/5	5/5	5/5
Support OLAP	5%	5/5	3/5	2/5
Score final	100%	5.0/5	3.4/5	2.7/5

PostgreSQL associé à PostGIS a été retenu comme solution principale en raison de ses capacités géospatiales avancées, de sa compatibilité avec les architectures OLAP et de sa robustesse pour les traitements analytiques du projet ECOTRACK. sa maturité et sa stabilité.

2.7. Comparaison des frameworks Machine Learning

Afin de sélectionner la bibliothèque la plus adaptée aux besoins du projet ECOTRACK, une étude comparative a été réalisée entre Scikit-learn, XGBoost, TensorFlow et PyTorch, afin d'identifier la solution la plus adaptée aux traitements analytiques sur données tabulaires IoT.

Tableau 16 : Tableau comparatif

Critères	XGBoost	Scikit-learn	TensorFlow	PyTorch
ML classique 20%	5/5	5/5	3/5	3/5
Données tabulaires	5/5	5/5	3/5	4/5
Déséquilibre classes	5/5	5/5	4/5	4/5
Intégration Python	5/5	2/5	5/5	5/5
Score final	4.9/5	4.7/5	3.8/5	3.9/5

Scikit-learn a été retenu comme framework principal de Machine Learning pour le prétraitement, l'encodage et l'évaluation des modèles. XGBoost a été retenu en complément

pour l'entraînement des modèles prédictifs XGBRegressor pour la régression et XGBClassifier pour la classification en raison de sa performance sur données tabulaires déséquilibrées et son paramètre `scale_pos_weight` adapté au déséquilibre du projet.

2.8. Choix d'une architecture OLAP

Le projet ECOTRACK nécessite l'analyse de grands volumes de données historiques issues des capteurs IoT, des opérations de collecte et des événements géolocalisés. Dans ce contexte, une architecture OLAP (Online Analytical Processing) a été privilégiée plutôt qu'une architecture OLTP (Online Transaction Processing).

Les systèmes OLTP sont principalement conçus pour gérer des transactions unitaires rapides, telles que les opérations bancaires ou les applications de gestion classique. Ils sont optimisés pour les insertions, mises à jour et suppressions fréquentes, mais restent moins adaptés aux analyses multidimensionnelles complexes.

À l'inverse, une architecture OLAP permet :

- l'analyse historique des données ;
- la création de tableaux de bord décisionnels ;
- l'agrégation multidimensionnelle ;
- l'analyse temporelle et géospatiale ;
- le support des modèles prédictifs.

Le choix d'un Data Warehouse orienté OLAP permet ainsi d'optimiser les performances analytiques et répondre efficacement aux besoins de pilotage décisionnel et de prédiction Machine Learning du projet ECOTRACK.

Tableau 17 : comparatif OLTP vs OLAP

Critères	OLTP	OLAP
Objectif principal	Transactions rapides	Analyse décisionnelle
Type de données	Temps réel transactionnel	Historique et analytique
Requêtes complexes	Peu adaptées	Très adaptées
Agrégation multidimensionnelle	Limitée	Excellente
Volume historique	Faible à moyen	Très important
Optimisation BI	Faible	Excellente
Adapté au projet ECOTRACK	Non	Oui

2.9. Contraintes légales et réglementaires

• Protection des données personnelles (RGPD)

Le projet ECOTRACK repose sur la collecte et l'exploitation de données issues de capteurs IoT répartis dans l'espace urbain. Bien que les données collectées soient principalement techniques et environnementales, certaines informations indirectes liées aux opérations municipales, aux trajets des véhicules de collecte ou aux localisations géographiques peuvent être considérées comme sensibles dans le cadre du Règlement Général sur la Protection des Données (RGPD).

Afin de garantir la conformité réglementaire, plusieurs principes devront être respectés :

- minimisation des données collectées ;
- limitation des accès aux données sensibles ;
- sécurisation des échanges et des connexions ;

- traçabilité des traitements effectués ;
- conservation limitée dans le temps ;
- anonymisation ou pseudonymisation lorsque nécessaire.

Le projet devra également garantir la confidentialité, l'intégrité et la disponibilité des données conformément aux exigences européennes relatives à la protection des données.

• **Politique de rétention des données IoT**

Les capteurs IoT génèrent un volume important de données temporelles et géospatiales. Une politique de rétention des données devra donc être mise en place afin d'éviter une croissance excessive des volumes stockés.

La stratégie de conservation proposée est la suivante :

Tableau 18 : Politique de rétention des données IoT

Type de données	Durée de conservation
Données brutes IoT	12 mois
Données agrégées analytiques	5 ans
Logs système	6 mois
Données ML transformées	3 ans
Sauvegardes	30 jours glissants

Cette politique permettra d'optimiser les coûts de stockage tout en conservant les données nécessaires aux analyses historiques et aux traitements prédictifs.

• **Obligations CNIL et sécurité des données**

Dans le cadre d'un projet municipal couvrant potentiellement plus de 500 000 habitants, plusieurs recommandations de la CNIL devront être prises en considération.

Les principales obligations concernent :

- la sécurisation des accès administrateurs ;
- le chiffrement des données sensibles ;
- la journalisation des accès ;
- la mise en place de sauvegardes régulières ;
- la gestion des habilitations utilisateurs ;
- l'audit des traitements de données.

Une attention particulière devra également être portée à la cybersécurité des infrastructures hébergeant les données IoT et les composants analytiques.

• **Gouvernance et traçabilité des données**

Le projet ECOTRACK nécessite une gouvernance claire des données afin de garantir leur qualité, leur cohérence et leur exploitation sécurisée.

Les mécanismes suivants sont prévus :

- validation des données à l'ingestion ;
- suivi des transformations ETL ;
- historisation des traitements ;
- contrôle des accès utilisateurs ;
- documentation des flux de données ;

- supervision des pipelines analytiques.

Cette approche permettra d'assurer la fiabilité des analyses décisionnelles et la conformité réglementaire de la plateforme Data Engineering.

3. Tendances et innovations 2025

L'évolution rapide des technologies Data Engineering et Big Data influence fortement les architectures modernes orientées IoT et analytique décisionnelle. Plusieurs tendances technologiques ont été identifiées comme particulièrement pertinentes pour le projet ECOTRACK.

3.1 Data Lakehouse

Les architectures Data Lakehouse représentent aujourd'hui une évolution majeure des plateformes analytiques. Elles permettent de combiner :

- la flexibilité des Data Lakes ;
- les performances analytiques des Data Warehouses.

Cette approche facilite :

- l'analyse SQL sur données massives ;
- la gouvernance des données ;
- la gestion des traitements analytiques ;
- l'intégration des modèles Machine Learning.

Dans le cadre d'ECOTRACK, cette tendance ouvre la possibilité d'évoluer progressivement vers une architecture hybride orientée analytics avancés.

3.2 Real-Time Analytics

Les traitements analytiques temps réel deviennent essentiels dans les architectures IoT modernes.

Cette tendance permet :

- la supervision instantanée des conteneurs ;
- la détection rapide des anomalies ;
- l'amélioration de la réactivité opérationnelle ;
- la génération d'alertes temps réel.

Dans ECOTRACK, cette tendance ouvre la possibilité d'intégrer à terme des traitements temps réel via Kafka ou Spark Streaming pour améliorer la réactivité opérationnelle du système.

3.3 Data Quality Observability

La surveillance continue de la qualité des données constitue aujourd'hui un enjeu majeur dans les architectures Big Data.

Les outils modernes de Data Observability permettent :

- la détection automatique d'anomalies ;
- le suivi de la fraîcheur des données ;
- la supervision des pipelines ETL ;
- l'identification des erreurs de transformation.

Dans ECOTRACK, cette approche est particulièrement importante en raison de la volumétrie des données IoT et de leur impact sur les analyses décisionnelles.

3.4 Edge Computing et IoT

L'Edge Computing consiste à rapprocher les traitements des équipements IoT afin de réduire la latence et limiter les transferts réseau.

Cette tendance permet :

- des traitements plus rapides ;
- une meilleure réactivité ;
- une réduction de la bande passante ;
- une amélioration de la résilience des systèmes IoT.

À long terme, ECOTRACK pourrait intégrer des mécanismes de prétraitement directement au niveau des capteurs ou des passerelles IoT.

3.5 Intelligence Artificielle Prédicative

Les modèles prédictifs occupent une place de plus en plus importante dans les projets Smart City et Data Engineering.

Dans ECOTRACK, les modèles prédictifs ont été implémentés et déployés:

- prévision du taux de remplissage J+1 via XGBoost Régression ;
- détection des débordements à 24h via XGBoost Classification;
- détection automatique des anomalies capteurs via Isolation Forest;

Cette base solide ouvre la voie à des évolutions comme l'optimisation prédictive des tournées et l'amélioration des indicateurs environnementaux.

4. Choix technologiques retenus pour ECOTRACK

Suite à l'analyse comparative réalisée précédemment, plusieurs technologies ont été retenues afin de construire une architecture cohérente, évolutive et adaptée aux besoins du projet.

Composant	Technologie retenue	Justification
Stockage objet	MinIO	Compatible S3, scalable et open-source
Base analytique	PostgreSQL + PostGIS	Gestion relationnelle et géospatiale
Séries temporelles	TimescaleDB	Optimisation des données IoT
Streaming	Apache Kafka	Ingestion temps réel performante
Traitement distribué	Apache Spark	Scalabilité et performance
Orchestration ETL	Apache Airflow	Gestion avancée des pipelines
Transformation analytique	dbt	Versioning et maintenabilité
Dashboards analytiques	Power BI	Visualisations avancées
Conteneurisation	Docker	Déploiement et portabilité
Machine Learning	XGBoost	Régression + Classification prédictive
Dashboard ML	Streamlit Cloud	Interface prédictive déployée
Détection anomalies	Isolation Forest	Apprentissage non supervisé
Langage principal	Python	Flexibilité · ML · ETL
Environnement ML	Google Colab	Développement et entraînement ML
Versioning	GitHub	Collaboration et CI/CD

Ces technologies ont été sélectionnées pour leur :

- maturité ;
- compatibilité avec les architectures Data modernes ;

- bonnes performances analytiques ;
- forte adoption dans le domaine du Data Engineering.

L'ensemble de ce stack permet de répondre efficacement aux contraintes du projet ECOTRACK liées :

- à la volumétrie ;
- aux traitements analytiques ;
- aux données géospatiales ;
- aux modèles prédictifs Machine Learning.

5. Plan de veille continue

Afin d'assurer l'évolution technologique du projet ECOTRACK, une veille continue sera maintenue tout au long du cycle de vie du système.

Cette veille portera principalement sur :

- les évolutions des outils Data Engineering ;
- les nouvelles solutions Big Data ;
- les frameworks de streaming ;
- les outils d'observabilité ;
- les technologies Machine Learning et IA.

Les principales ressources de veille utilisées seront :

- GitHub ;
- Stack Overflow ;
- Medium ;
- conférences spécialisées ;
- newsletters techniques ;
- documentations officielles.

Une veille hebdomadaire permettra :

- d'anticiper les évolutions technologiques ;
- d'identifier les bonnes pratiques ;
- de surveiller les risques techniques ;
- d'améliorer progressivement l'architecture du projet.

Conclusion de la veille technologique

La veille technologique réalisée dans le cadre du projet ECOTRACK a permis d'identifier les solutions les plus adaptées aux besoins d'une architecture Data Engineering orientée IoT, analytique décisionnelle et Machine Learning prédictif.

Les différentes comparaisons effectuées montrent que les technologies retenues présentent un bon équilibre entre : performances, scalabilité, maintenabilité, intégration, coût.

Cette veille a également permis d'identifier des perspectives d'évolution futures : temps réel via Kafka, architecture Lakehouse et optimisation prédictive des tournées.

L'ensemble du stack retenu constitue ainsi une base cohérente et évolutive pour la mise en œuvre de la plateforme ECOTRACK.

Chapitre 4 : Architecture Data Lake & Pipelines

L'architecture Data du projet ECOTRACK repose sur une approche orientée Data Engineering permettant de collecter, transformer, stocker et exploiter les données issues des conteneurs connectés et des systèmes opérationnels. L'objectif principal de cette architecture est de garantir la scalabilité, la fiabilité et la performance des outils de transformation analytique et de Machine Learning tout en assurant une bonne gouvernance des données.




Figure 1 : Architecture Data Lake

L'architecture retenue s'appuie sur plusieurs composants complémentaires :

- une architecture Data Lake organisée en couches ;
- des pipelines ELT automatisés ;
- une base analytique PostgreSQL/PostGIS ;
- des outils de traitement distribués ;
- des outils de visualisation décisionnelle.

Cette organisation permet :

- l'ingestion des données IoT ;
- la transformation et la validation des données ;
- le stockage optimisé des données analytiques ;
- la production de tableaux de bord et d'indicateurs décisionnels.

1. Architecture Data Lake

L'architecture Data Lake mise en place dans ECOTRACK repose sur une organisation des données en plusieurs couches afin d'assurer la qualité, la traçabilité et l'exploitation analytique des données.

Le stockage objet est assuré par MinIO, une solution compatible S3 permettant de gérer efficacement les données brutes, transformées et historisées.

1.1. Bronze Layer : Données brutes

La couche Bronze constitue le niveau d'ingestion initial des données. Elle contient les données brutes provenant :

- des capteurs IoT ;
- des fichiers CSV ;
- des données opérationnelles ;
- des sources externes.

Les données sont stockées principalement aux formats :

- JSON ;
- Parquet ;
- CSV.

Cette couche permet :

- l'historisation complète des données ;
- la conservation des données originales ;
- la traçabilité des traitements.

Les données sont partitionnées par date afin d'optimiser les performances de lecture et de stockage.

1.2. Silver Layer : Données nettoyées

La couche Silver contient les données transformées et nettoyées après traitement des pipelines ETL.

Les principales opérations réalisées sont :

- suppression des doublons ;
- normalisation des formats ;
- validation des valeurs ;
- enrichissement des données ;
- contrôle qualité.

Cette couche permet de produire des données fiables et cohérentes destinées aux traitements analytiques et décisionnels.

Les validations qualité sont réalisées à l'aide de :

- dbt tests ;
- Great Expectations ;
- Pydantic.

1.3 Gold Layer : Données analytiques

La couche Gold contient les données prêtes pour l'analyse métier et les dashboards décisionnels.

Elle regroupe :

- les agrégats analytiques ;
- les indicateurs KPI ;
- les tables décisionnelles ;
- les Data Marts.

Cette couche est optimisée pour :

- les requêtes analytiques ;
- les tableaux de bord Power BI ;
- les traitements Machine Learning — notamment la vue VW_ML_DATASET pour l'entraînement des modèles prédictifs.

2. Architecture des pipelines de données

Les pipelines de données jouent un rôle central dans l'architecture ECOTRACK. Ils assurent l'ingestion, la transformation, la validation et le chargement des données dans les différentes couches du système.

2.1 Ingestion des données

L'ingestion des données est réalisée à partir :

- des capteurs IoT ;
- des données opérationnelles ;
- des fichiers historiques.

Apache Kafka sera utilisé pour la gestion des flux temps réel afin d'assurer :

- une ingestion continue ;
- une faible latence ;
- une bonne tolérance aux pannes.

Les données sont ensuite stockées dans le Bronze Layer du Data Lake.

2.2 Transformation des données

Les traitements de transformation sont réalisés avec :

- Apache Spark ;
- dbt ;
- SQL analytique.

Ces transformations permettent :

- le nettoyage des données ;
- l'application des règles métier ;
- la création des agrégats ;
- la préparation des données analytiques.

Le format Parquet est privilégié afin d'optimiser :

- la compression ;
- les performances de lecture ;
- les traitements analytiques.

2.3 Orchestration des pipelines

Apache Airflow est utilisé comme orchestrateur principal des pipelines ELT.

Airflow permet :

- la planification des traitements ;
- la gestion des dépendances ;
- la supervision des DAGs ;
- le monitoring des erreurs ;
- l'automatisation des workflows.

Les traitements sont organisés sous forme de DAGs permettant de structurer les différentes étapes du pipeline de données.

2.4 Validation et qualité des données

La qualité des données constitue un enjeu majeur dans le projet ECOTRACK.

Plusieurs mécanismes sont mis en place :

- validation des schémas ;
- contrôle des types ;
- détection des anomalies ;
- surveillance des pipelines.

Les principaux outils utilisés sont :

- Great Expectations ;
- dbt tests ;
- Pydantic.

Ces validations permettent de garantir :

- la cohérence des données ;
- la fiabilité des indicateurs ;
- la stabilité des dashboards analytiques.

3. Architecture de stockage

3.1 PostgreSQL et PostGIS

PostgreSQL constitue la base analytique principale du projet.

L'extension PostGIS permet de gérer :

- les données géographiques ;
- les coordonnées GPS ;
- les requêtes spatiales ;
- les analyses géospatiales.

Cette approche permet :

- l'analyse des zones de collecte ;
- l'optimisation des tournées ;
- la visualisation cartographique.

3.2 TimescaleDB

TimescaleDB est utilisé pour optimiser la gestion des séries temporelles issues des capteurs IoT.

Cette extension permet :

- le partitionnement automatique ;
- la compression des données ;
- les agrégations temporelles ;
- l'amélioration des performances analytiques.

Les données sont organisées sous forme d'hypertables afin de faciliter :

- les requêtes historiques ;
- les analyses temporelles ;
- les indicateurs temps réel.

3.3 MinIO

MinIO est utilisé comme solution de stockage objet compatible S3.

Cette solution permet :

- le stockage des fichiers bruts ;

- l'archivage des données ;
- la gestion des formats analytiques ;
- l'historisation des données.

MinIO offre également :

- une bonne scalabilité ;
- un contrôle des accès ;
- des mécanismes de sauvegarde et de versioning.

4. Architecture analytique et visualisation

L'architecture analytique d'ECOTRACK permet de transformer les données collectées en indicateurs exploitables pour les gestionnaires et les équipes opérationnelles. Cette couche analytique repose sur des outils de Business Intelligence et de visualisation capables de fournir des tableaux de bord interactifs et des analyses décisionnelles.

4.1 Power BI

Power BI constitue l'outil principal de visualisation analytique du projet.

Il permet :

- la création de dashboards interactifs ;
- le suivi des indicateurs KPI ;
- l'analyse des performances de collecte ;
- la visualisation des tendances temporelles ;
- l'analyse géographique des conteneurs.

Les dashboards développés permettent notamment :

- le suivi du taux de remplissage ;
- l'analyse des tournées ;
- la supervision des alertes ;
- le suivi des incidents ;
- l'analyse des performances opérationnelles.

Power BI offre également :

- des mécanismes de filtrage dynamiques ;
- des visualisations interactives ;
- des capacités d'export et de reporting.

4.2 Streamlit

Streamlit constitue l'application déployer pour le dashboard prédictif ECOTRACK, accessible publiquement sur Streamlit Cloud 24h/24. Il permet une vue globale sur :

- KPI Globaux
- Top conteneurs
- Carte France : alertes géolocalisées
- Analyse par ville : avg_fill et alertes ROUGE par ville
- Anomalies capteurs
- Évolution temporelle

4.3 API Analytics

Une API analytique FastAPI pourrait être développée à terme afin d'exposer les indicateurs et prédictions ECOTRACK aux systèmes externes notamment pour une intégration dans des applications Smart City tierces.

Cette API permettra :

- l'accès aux indicateurs métier ;
- l'exposition des agrégats analytiques ;
- l'intégration avec les dashboards ;
- l'accès aux données historiques.

Les principales fonctionnalités de cette API sont :

- la récupération des KPIs ;
- les statistiques temporelles ;
- les indicateurs géographiques ;
- les données de prédiction futures.

5. Scalabilité et performances

L'architecture ECOTRACK a été conçue afin de répondre aux contraintes de volumétrie et de performance liées aux données IoT et analytiques.

5.1 Scalabilité horizontale

La scalabilité horizontale permet d'augmenter les capacités du système en ajoutant de nouvelles instances de traitement ou de stockage.

Cette approche est utilisée pour :

- les brokers Kafka ;
- les traitements Spark ;
- les pipelines Airflow ;
- le stockage objet MinIO.

Cette stratégie permet :

- d'augmenter les performances ;
- de réduire les risques de saturation ;
- d'améliorer la résilience du système.

5.2 Optimisation des performances

Plusieurs mécanismes d'optimisation sont mis en œuvre dans l'architecture :

- partitionnement des données ;
- utilisation du format Parquet ;
- indexation PostgreSQL/PostGIS ;
- compression TimescaleDB ;
- agrégats pré-calculés ;
- cache analytique.

Ces optimisations permettent :

- de réduire les temps de traitement ;
- d'améliorer les performances des dashboards ;
- de garantir une faible latence analytique.

5.3 Objectifs de performance

Les objectifs de performance définis pour ECOTRACK sont les suivants :

Tableau 19 : Objectifs de performance

Indicateur	Objectif
Latence ingestion	< 2 secondes
Temps réponse dashboards	< 5 secondes
Disponibilité système	≥ 99,5 %
Temps exécution pipelines	< 30 minutes
Qualité des données	≥ 95 %

Ces objectifs permettent d'assurer une bonne qualité de service et une exploitation analytique efficace des données.

6. Sécurité et gouvernance des données

La sécurité et la gouvernance des données constituent des éléments essentiels dans l'architecture ECOTRACK.

6.1 Sécurité des données

Plusieurs mécanismes de sécurité sont mis en œuvre afin de protéger les données et les traitements analytiques :

- authentification sécurisée ;
- gestion des rôles et permissions ;
- chiffrement des données sensibles ;
- sauvegardes automatisées ;
- supervision des accès.
- accès SSH sécurisé au serveur

Les accès aux bases analytiques, aux outils BI et streamlit sont contrôlés afin de limiter les risques de fuite ou de modification des données.

6.2 Gouvernance des données

La gouvernance des données permet d'assurer :

- la qualité ;
- la traçabilité ;
- la cohérence ;
- l'historisation des données.

Les principales mesures mises en œuvre sont :

- documentation des pipelines ;
- versioning des transformations dbt ;
- suivi des traitements Airflow ;
- validation qualité automatisée ;
- historisation des données IoT.

Cette approche garantit une meilleure fiabilité des indicateurs analytiques produits par la plateforme.

Conclusion de l'architecture

L'architecture logicielle du projet ECOTRACK repose sur une approche moderne de Data Engineering permettant de gérer efficacement les traitements analytiques, les données IoT et les analyses géospatiales.

L'utilisation combinée d'Airflow, dbt, PostgreSQL/PostGIS, MinIO, XGBoost, Streamlit et Power BI permet de construire une plateforme:

- scalable ;
- performante ;
- maintenable ;
- adaptée aux contraintes Big Data.

L'architecture mise en place garantit également :

- une bonne qualité des données ;
- une supervision efficace des pipelines ;
- une exploitation analytique avancée ;

Cette architecture constitue ainsi une base solide pour le développement de la plateforme intelligente ECOTRACK.

Chapitre 5 : Modélisation des données

1. Objectifs de la modélisation

La modélisation des données constitue une étape essentielle dans le projet ECOTRACK. Elle permet de structurer les données collectées afin de garantir leur cohérence, leur exploitabilité analytique et leur intégration dans l'architecture décisionnelle du système.

L'objectif principal est de concevoir un modèle de données capable de :

- gérer les données IoT ;
- historiser les mesures des conteneurs ;
- faciliter les analyses géospatiales ;
- optimiser les traitements analytiques ;
- alimenter les dashboards décisionnels ;
- préparer l'intégration des modèles prédictifs.

La modélisation repose sur une approche orientée Data Warehouse combinant :

- données temporelles ;
- données géographiques ;
- indicateurs analytiques ;
- structures décisionnelles.

2. Approche de modélisation retenue

Le projet ECOTRACK adopte une approche de modélisation décisionnelle basée sur un modèle en constellation (Galaxy Schema). Cette approche permet de représenter plusieurs processus métier à travers plusieurs tables de faits partageant des dimensions communes.

Contrairement à un schéma en étoile classique centré sur une seule table de faits, le modèle en constellation permet de mieux représenter la complexité des traitements analytiques du projet ECOTRACK, notamment :

- les mesures IoT ;
- les opérations de collecte ;
- les analyses temporelles ;
- les analyses géospatiales.

Le modèle repose principalement sur :

- des tables de dimensions ;
- plusieurs tables de faits ;
- des dimensions partagées ;
- des mécanismes d'historisation SCD Type 2.

Cette approche permet :

- une meilleure modularité analytique ;
- une réutilisation des dimensions ;
- une optimisation des requêtes décisionnelles ;
- une meilleure évolutivité du Data Warehouse.

3. Modélisation conceptuelle des données (MCD)

Le modèle conceptuel des données permet d'identifier les principales entités manipulées dans le système ECOTRACK ainsi que leurs relations.




Figure 2 : MCD

4. Modélisation logique des données (MLD)

Le modèle logique traduit les entités métier en tables relationnelles exploitables dans PostgreSQL.

DIM_DEVICE(device_sk, device_bk, model, installation_date, is_active)

DIM_WASTE_TYPE(waste_type_sk, waste_type_bk, waste_type_name)

DIM_CONTAINER(container_sk, container_bk, container_type, capacity_l, zone_bk, status, latitude, longitude, geom, date_debut, date_fin, version, is_current, created_at)

DIM_TIME(time_sk, date_bk, day_number, month_number, month_name, quarter, year_time, day_of_week, is_weekend)

DIM_ZONE(zone_sk, zone_bk, zone_name, city, population, area_km2, latitude, longitude, geom)

DIM_AGENT(agent_sk, agent_bk, firstname, lastname, role, is_active)

DIM_ROUTE(route_sk, route_bk, route_date, planned_distance_m, planned_duration_min, actual_distance_m, actual_duration_min, path)

FACT_MEASUREMENT(measurement_sk, #time_sk, #container_sk, #device_sk, #zone_sk, #waste_type_sk, measurement_timestamp, taux_remplissage_pct, volume_litres, poids_estime_kg, temperature_c, batterie_pct, is_overflow)

FACT_COLLECTE(collecte_sk, #time_sk, #route_sk, #container_sk, #zone_sk, #agent_sk, visit_datetime, visit_order, taux_remplissage_pct, volume_collecte_litres, poids_collecte_kg, is_overflow)

5. Modélisation physique des données (MPD)

Le modèle physique correspond à l'implémentation réelle des tables dans PostgreSQL/PostGIS et TimescaleDB.

Plusieurs optimisations sont mises en œuvre :

- indexation des colonnes critiques ;
- index géospatiaux PostGIS ;
- hypertables TimescaleDB ;
- partitionnement temporel ;
- compression des données anciennes.

Les principales structures utilisées sont :

- clés primaires ;
- clés étrangères ;
- index GiST pour les données spatiales ;
- contraintes d'intégrité ;
- partitionnement par date.

Cette approche permet :

- d'améliorer les performances ;
- d'optimiser le stockage ;
- de faciliter les traitements analytiques.

Conclusion de la modélisation

La modélisation des données du projet ECOTRACK repose sur une architecture décisionnelle en constellation (Galaxy Schema) adaptée aux contraintes des systèmes Big Data, IoT et analytiques. Cette approche permet de représenter plusieurs processus métier à travers différentes tables de faits partageant des dimensions communes, notamment les dimensions temporelles, géographiques et opérationnelles. L'utilisation d'un modèle en constellation améliore la cohérence du Data Warehouse, facilite la réutilisation des dimensions analytiques et optimise les traitements décisionnels. L'intégration de PostgreSQL/PostGIS et TimescaleDB permet également de gérer efficacement les données géospatiales et les séries temporelles issues des capteurs IoT. Cette modélisation offre ainsi une base robuste et évolutive pour l'analyse des performances de collecte, la supervision des conteneurs, l'alimentation des dashboards décisionnels et l'intégration future de modèles de Machine Learning et d'intelligence artificielle prédictive.

Chapitre 6 : Planification agile

1. Choix de la méthodologie Agile

Dans le cadre du projet ECOTRACK, la méthodologie Agile Scrum a été retenue afin d'assurer une gestion itérative, collaborative et progressive du développement. Cette approche est particulièrement adaptée aux projets Data & Analytics en raison de la nature évolutive des traitements analytiques, des pipelines de données et des modèles de Machine Learning.

Le projet ECOTRACK combine plusieurs composantes techniques complexes :

- un Data Warehouse ;
- des traitements ELT ;
- des analyses décisionnelles ;
- des modèles Machine Learning ;
- des dashboard analytiques interactifs.

Dans ce contexte, l'approche Scrum permet :

- une meilleure adaptation aux contraintes techniques ;
- une validation progressive des livrables ;
- une amélioration continue des pipelines analytiques ;
- une meilleure collaboration entre les membres de l'équipe.

L'un des principaux avantages observés durant le projet concerne la capacité d'adaptation rapide face aux contraintes d'infrastructure. Initialement, le projet prévoyait la génération de 500 000 mesures IoT par jour sur une année complète, représentant environ 182 millions de lignes. Toutefois, ce volume s'est révélé incompatible avec les ressources du VPS collaboratif utilisé par l'équipe. Grâce à l'approche Agile Scrum, une révision rapide des objectifs techniques a été réalisée dès le sprint suivant afin de réduire le volume à 50 000 mesures par jour, soit environ 19,4 millions de lignes sur 384 jours, tout en conservant les objectifs analytiques du projet.

Cette flexibilité illustre l'intérêt de Scrum dans les projets Data Engineering où les contraintes techniques, les performances et les besoins analytiques peuvent évoluer rapidement au cours du développement.

2. Organisation de l'équipe projet

Le projet ECOTRACK a été réalisé par une équipe de trois membres disposant de compétences complémentaires en Data Engineering, Machine Learning et analytique décisionnelle.

Rôle	Responsable	Responsabilités principales
Product Owner	Olivier Ouedraogo	Vision produit, Machine Learning, dashboard prédictif
Scrum Master	Ferdinand HOUNGBEME	Infrastructure, PostgreSQL/PostGIS, ETL Airflow, dashboard
Expert Data	Dany	MCD/MPD, requêtes analytiques, documentation

Cette répartition des responsabilités a permis d'assurer :

- une bonne coordination du projet ;
- une spécialisation des tâches ;
- une meilleure productivité ;
- une collaboration efficace entre les différentes composantes techniques du système.

3. Framework Scrum adopté

Le framework Scrum utilisé dans le cadre du projet repose sur plusieurs cérémonies Agile organisées tout au long du cycle de développement.

Les principales cérémonies mises en œuvre sont :

- **Sprint Planning** : planification des User Stories à réaliser durant le sprint ;
- **Daily Stand-up** : point quotidien permettant de suivre l'avancement et les blocages ;
- **Sprint Review** : présentation des livrables réalisés ;
- **Sprint Retrospective** : analyse des améliorations possibles pour les sprints suivants.

Le projet a été organisé selon les paramètres suivants :

- durée d'un sprint : 2 semaines ;
- nombre total de sprints : 8 ;
- durée globale du projet : 16 semaines.

Cette organisation a permis d'assurer une progression régulière du projet tout en facilitant l'intégration progressive des différents composants analytiques et techniques.

4. Backlog produit

Le backlog produit regroupe l'ensemble des fonctionnalités identifiées pour le projet ECOTRACK. Les User Stories ont été priorisées selon la méthode MoSCoW (Must Have, Should Have, Could Have, Won't Have) afin de structurer les priorités fonctionnelles et techniques du projet.

Les principales catégories fonctionnelles du backlog sont les suivantes :

Epic	Fonctionnalités principales
Infrastructure & Data Warehouse	PostgreSQL/PostGIS, hébergement VPS, schéma DW
ETL & Analytics	ingestion des données, requêtes analytiques
Machine Learning	Feature Engineering, modèles prédictifs
Dashboard & Visualisation	KPIs, cartes interactives, supervision
Business Intelligence	Rapports analytiques et exploration BI

Les principales User Stories retenues sont présentées ci-dessous :

ID	User Story	Priorité	Story Points
US-001	En tant que Data Engineer, je veux charger les données IoT dans PostgreSQL/PostGIS afin d'alimenter le Data Warehouse	MUST	13
US-002	En tant que Data Analyst, je veux analyser les niveaux de remplissage afin d'identifier les conteneurs critiques	MUST	8
US-003	En tant que système ELT, je veux automatiser les transformations afin de garantir la qualité des données	MUST	8
US-004	En tant que Gestionnaire, je veux consulter un dashboard analytique afin de suivre les indicateurs clés	MUST	5

US-005	En tant que Data Scientist, je veux entraîner un modèle XGBoost afin de prédire les débordements	MUST	13
US-006	En tant qu'Analyste métier, je veux visualiser les zones critiques sur une carte afin d'optimiser les tournées	SHOULD	5
US-007	En tant que Pipeline ELT, je veux historiser les données IoT afin de permettre les analyses temporelles	MUST	8
US-008	En tant que Gestionnaire, je veux recevoir des alertes de débordement afin d'intervenir rapidement	SHOULD	5
US-009	En tant qu'Administrateur, je veux superviser les DAGs Airflow afin de détecter les anomalies pipeline	SHOULD	5
US-010	En tant que système analytique, je veux exporter les prédictions ML vers PostgreSQL afin d'alimenter le dashboard	MUST	8
US-011	En tant qu'utilisateur, je veux exporter les rapports analytiques au format PDF	COULD	3
US-012	En tant qu'administrateur, je veux recevoir des notifications email automatiques	COULD	3
US-013	En tant qu'utilisateur mobile, je veux consulter les indicateurs depuis un smartphone	COULD	5
US-014	En tant qu'administrateur, je veux personnaliser les dashboards analytiques	COULD	5
US-015	En tant que système analytique, je veux intégrer une analyse vidéo temps réel des déchets	WON'T	13
US-016	En tant qu'utilisateur, je veux utiliser un assistant vocal intelligent	WON'T	8
US-017	En tant qu'architecte Cloud, je veux déployer la plateforme sur une architecture multi-cloud	WON'T	13

5. Organisation des sprints

Le projet ECOTRACK a été structuré en huit sprints permettant de développer progressivement les différentes composantes techniques et analytiques du système.

Sprint	Objectif principal	Livrables clés
Sprint 1	Infrastructure & modélisation	VPS, PostgreSQL/PostGIS, MCD/MPD
Sprint 2	Chargement des données	ETL, 19.4M lignes chargées
Sprint 3	Vue ML & Feature Engineering	VW_ML_DATASET
Sprint 4	Analyse exploratoire	EDA et corrélations

Sprint 5	Modèles Machine Learning	XGBoost & Isolation Forest
Sprint 6	Export des prédictions	DW.PREDICTIONS
Sprint 7	Dashboard analytique	Streamlit Dashboard
Sprint 8	BI & documentation	Documentation finale

Cette organisation progressive a permis :

- une validation continue des livrables ;
- une meilleure maîtrise des risques ;
- une amélioration progressive des performances analytiques ;
- une intégration continue des fonctionnalités.

6. Outils de gestion et collaboration

Plusieurs outils ont été utilisés afin de faciliter la gestion du projet, le suivi des tâches et la collaboration entre les membres de l'équipe.

Outil	Utilisation
GitHub Projects	Gestion backlog et Kanban
GitHub	Versioning et collaboration
WhatsApp	Communication équipe
PostgreSQL/PostGIS	Data Warehouse
Apache Airflow	Orchestration ETL
Streamlit Cloud	Dashboard analytique
pgAdmin 4	Administration et requêtes SQL
Google Colab	Développement ML

Ces outils ont permis d'assurer :

- la traçabilité des développements ;
- la collaboration à distance ;
- l'automatisation des pipelines ;
- la supervision des traitements analytiques.

7. Indicateurs clés de performance (KPI)

Afin d'évaluer les performances du projet et de l'architecture analytique, plusieurs KPIs sont définis.

KPI	Objectif
Qualité des données	$\geq 95 \%$
Latence pipeline	< 2 secondes
Temps réponse dashboards	< 5 secondes
Disponibilité pipelines	$\geq 99 \%$

Volume traité par jour	≥ 500 000 mesures
Taux erreur ETL	< 1 %
Temps exécution DAGs	< 30 minutes
Disponibilité plateforme	≥ 99,5 %

Ces indicateurs permettent d'assurer :

- le suivi des performances ;
- la qualité des données ;
- la stabilité des pipelines ;
- l'efficacité des traitements analytiques.

8. Gestion des risques

Plusieurs risques techniques et organisationnels ont été identifiés durant le projet.

Risque	Impact	Mitigation
Retard pipelines ETL	Élevé	Priorisation MVP
Saturation stockage	Moyen	Archivage et partitionnement
Mauvaise qualité données	Élevé	Validation automatisée
Dépassement budget cloud	Moyen	Monitoring ressources
Défaillance pipeline	Élevé	Supervision Airflow
Problèmes performances	Moyen	Optimisation PostgreSQL

Cette gestion proactive des risques a permis d'assurer :

- la stabilité du projet ;
- la qualité des données ;
- les performances des traitements analytiques ;
- le respect des contraintes techniques.

9. Diagramme de Gantt

Le diagramme de Gantt permet de visualiser la répartition des tâches et des livrables sur l'ensemble du projet ECOTRACK. Le projet a été organisé en 8 sprints répartis sur une durée totale de 16 semaines selon la méthodologie Scrum. Chaque sprint correspond à une phase précise du développement de l'architecture Data, des pipelines analytiques et des modèles de Machine Learning.




Figure 3 : Diagramme de Gantt

Les principaux jalons du projet concernent :

- la mise en place du Data Warehouse ;
- le chargement des données ;
- la création de la vue ML ;
- l'entraînement des modèles ;
- le développement du dashboard ;
- Le déploiement de l'application prédictive
- la finalisation des rapports et de la soutenance.

Conclusion de la planification Agile

La planification Agile mise en place dans le cadre du projet ECOTRACK permet d'organiser efficacement le développement des composants Data Engineering, des pipelines analytiques, des modèles Machine Learning et des dashboards décisionnels. L'utilisation du framework Scrum facilite la livraison progressive des fonctionnalités tout en assurant une meilleure gestion des priorités, des risques et des évolutions métier. L'organisation en sprints favorise également une validation continue es pipelines ETL, de la qualité des données, des modèles ML et des indicateurs analytiques. Cette approche offre ainsi un cadre structuré et évolutif permettant d'assurer la réussite du projet ECOTRACK dans un environnement orienté Big Data, IoT, Machine Learning prédictif et analytique décisionnelle.

Conclusion Générale

Le projet **ECOTRACK** a permis de concevoir une plateforme décisionnelle intelligente dédiée à l'optimisation de la gestion des déchets urbains grâce à l'exploitation des technologies de la donnée, du Big Data et de l'intelligence artificielle. L'étude de faisabilité a confirmé la pertinence technique, fonctionnelle et économique de la solution, tandis que la veille technologique a permis de sélectionner les outils les plus adaptés aux exigences du projet. La modélisation décisionnelle a conduit à la conception d'un Data Warehouse basé sur un modèle en constellation, garantissant une structuration cohérente et évolutive des données issues des capteurs IoT et des opérations de collecte.

L'architecture logicielle proposée repose sur un écosystème moderne intégrant PostgreSQL, PostGIS, TimescaleDB, Docker, Airflow, dbt, Scikit-learn, XGBoost et Streamlit, permettant d'assurer l'ingestion, le stockage, la transformation et l'exploitation des données à grande échelle. L'approche Agile adoptée tout au long du projet a facilité l'organisation des travaux, la planification des livrables et l'amélioration continue des différentes composantes de la plateforme. La planification par sprints et le suivi du projet à travers le diagramme de Gantt ont contribué à garantir une progression maîtrisée et cohérente des développements.

Ces capacités permettent non seulement d'améliorer l'efficacité opérationnelle des services urbains, mais également de réduire les coûts logistiques et l'impact environnemental associé aux déplacements inutiles.

L'impact opérationnel est démontré et chiffré : -90.1% de passages inutiles évités, soit 658 067 arrêts évités par an sur 2 000 conteneurs dans 10 villes.

Enfin, ECOTRACK constitue une base solide pour de futures évolutions. L'intégration de traitements temps réel, l'automatisation avancée des pipelines de données en production ou encore l'extension du système à de nouvelles zones géographiques représentent autant de perspectives d'amélioration. Par ailleurs le déploiement de modèles prédictifs en production est déjà opérationnel — le dashboard Streamlit accessible publiquement en témoigne. À travers ce projet, les principes du Data Engineering, de l'analytique décisionnelle et de l'intelligence artificielle ont été mobilisés de manière complémentaire afin de répondre à une problématique concrète de ville intelligente, démontrant ainsi le potentiel des technologies de la donnée au service du développement durable et de l'optimisation des services urbains.

Bibliographie et Sitographie

1. PostgreSQL Global Development Group. *PostgreSQL Documentation*. Disponible sur : <https://www.postgresql.org/docs/>
2. PostgreSQL Global Development Group. *PostGIS Documentation*. Disponible sur : <https://postgis.net/documentation/>
3. Timescale Inc. *TimescaleDB Documentation*. Disponible sur : <https://docs.timescale.com/>
4. Apache Software Foundation. *Apache Airflow Documentation*. Disponible sur : <https://airflow.apache.org/docs/>
5. dbt Labs. *dbt Documentation*. Disponible sur : <https://docs.getdbt.com/>
6. Docker Inc. *Docker Documentation*. Disponible sur : <https://docs.docker.com/>
7. MinIO Inc. *MinIO Documentation*. Disponible sur : <https://min.io/docs/>
8. Microsoft Corporation. *Power BI Documentation*. Disponible sur : <https://learn.microsoft.com/power-bi/>
9. Streamlit Inc. *Streamlit Documentation*. Disponible sur : <https://docs.streamlit.io/>
10. Scikit-Learn Developers. *Scikit-Learn Documentation*. Disponible sur : <https://scikit-learn.org/stable/documentation.html>
11. XGBoost Contributors. *XGBoost Documentation*. Disponible sur : <https://xgboost.readthedocs.io/>
12. Python Software Foundation. *Python Documentation*. Disponible sur : <https://docs.python.org/3/>
13. Pandas Development Team. *Pandas Documentation*. Disponible sur : <https://pandas.pydata.org/docs/>
14. NumPy Developers. *NumPy Documentation*. Disponible sur : <https://numpy.org/doc/>
15. Plotly Technologies Inc. *Plotly Documentation*. Disponible sur : <https://plotly.com/python/>
16. GitHub Inc. *GitHub Documentation*. Disponible sur : <https://docs.github.com/>
17. Scrum.org. *The Scrum Guide*. Disponible sur : <https://scrumguides.org/>
18. Kimball Group. *Dimensional Modeling Techniques*. Disponible sur : <https://www.kimballgroup.com/data-warehouse-business-intelligence-resources/>
19. Microsoft Learn. *Data Warehouse Architecture*. Disponible sur : <https://learn.microsoft.com/azure/architecture/data-guide/>
20. OpenStreetMap Foundation. *OpenStreetMap Documentation*. Disponible sur : <https://wiki.openstreetmap.org/>

21. Google Colab Google LLC. Google Colaboratory. Disponible sur :
<https://colab.research.google.com>
22. psycopg2 Psycopg Team. Psycopg2 Documentation. Disponible sur :
<https://www.psycopg.org/docs/>
23. Isolation Forest Scikit-learn. IsolationForest. Disponible sur :
[https://scikit-learn.org/stable/modules/
generated/sklearn.ensemble.IsolationForest.html](https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.IsolationForest.html)

Bibliographie

- Kimball, R., & Ross, M. (2013). *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling* (3rd Edition). Wiley.
- Kleppmann, M. (2017). *Designing Data-Intensive Applications*. O'Reilly Media.
- Han, J., Kamber, M., & Pei, J. (2012). *Data Mining: Concepts and Techniques* (3rd Edition). Morgan Kaufmann.
- Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow* (3rd Edition). O'Reilly Media.
- Russell, S., & Norvig, P. (2021). *Artificial Intelligence: A Modern Approach* (4th Edition). Pearson.
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of KDD 2016. Disponible sur : <https://arxiv.org/abs/1603.02754>