ECOTRACK - Projet Fil Rouge Master 1 Data

Analytics Avancés, Données Géospatiales et Machine Learning

Version : 3.0 (Version Pédagogique)
Date : Novembre 2025
Durée : 4 mois
Niveau : Master 1 - Expert en Architecture et Développement Logiciel (RNCP 38822)
Périmètre : 115 tâches sur 164 (70% du projet complet)
Focus : PostGIS, Analytics avancés (8+ graphiques), Machine Learning basique, DataViz

---

TABLE DES MATIÈRES

1. Introduction et Contexte
2. Objectifs Pédagogiques et Compétences RNCP
3. Périmètre Technique Master 1 Data
4. Architecture Data
5. PostGIS et Données Géospatiales
6. Analytics et DataViz Avancés
7. Machine Learning Basique
8. Pipeline ETL et Qualité Données
9. Stack Technique Data
10. Organisation et Méthodologie
11. Livrables et Jalons
12. Critères d'Évaluation
13. Ressources et Apprentissage

I. INTRODUCTION ET CONTEXTE

1.1 Présentation du Projet ECOTRACK

ECOTRACK est une plateforme intelligente de gestion des déchets urbains qui révolutionne la collecte grâce à l'IoT, l'optimisation algorithmique et surtout **l'analyse avancée des données**.

Votre mission en tant qu'étudiants Master 1 Data : Concevoir et développer la couche DATA et ANALYTICS de la plateforme avec :

- Modélisation géospatiale avancée (PostGIS) - **À APPRENDRE ET IMPLÉMENTER**

- Analytics multicouches (8+ types de graphiques)
- Dashboards interactifs et personnalisables
- Machine Learning basique (prédiction remplissage) - **À IMPLÉMENTER**
- Générateur de rapports automatisés
- Visualisations cartographiques avancées (heatmap, choroplèthe)
- Pipeline ETL et qualité des données

1.2 Contexte Métier Data

Données disponibles :

- 2000 conteneurs IoT (position, type, remplissage)
- 500 000 mesures/jour (historique 12 mois)
- 200 zones géographiques
- 500 tournées/mois
- 15 000 utilisateurs citoyens (actions, points, badges)

Enjeux Data :

- **Volumétrie** : 180M mesures/an à stocker et analyser
- **Performance** : Requêtes spatiales < 200ms
- **Insights** : Identifier patterns (jours/heures pic)
- **Prédiction** : Anticiper débordements (ML)
- **Reporting** : Rapports mensuels automatisés

1.3 Différence avec Bachelor Dev-Data

Aspect	Bachelor Dev-Data	Master 1 Data
BDD	PostgreSQL simple	PostgreSQL + PostGIS
Requêtes	SQL basique	SQL spatial avancé (ST_*, géométries)
Analytics	3 graphiques	8+ graphiques (heatmap, choroplèthe)
Carte	Leaflet statique	Leaflet avancé (clustering, heatmap)
Historique	Aucun	Graphiques évolution temporelle
ML	Aucun	Prédiction remplissage (régression)
Rapports	Export CSV	Générateur PDF/Excel automatisé
DataViz	Chart.js basique	Recharts + visualisations complexes
ETL	Aucun	Pipeline ETL automatisé

II. OBJECTIFS PÉDAGOGIQUES ET COMPÉTENCES RNCP

2.1 Compétences RNCP Niveau 7 Visées

Bloc 1 - Planifier et organiser (aspects Data)

C1.1 - Faisabilité projet data

- Analyse volumétrie (180M mesures/an)
- Choix architecture (OLTP vs OLAP)
- Estimation coûts stockage/compute

C1.2 - Veille technologique data

- Benchmark BDD spatiales (PostGIS vs MongoDB Geo vs MySQL Spatial)
- Analyse solutions ML (Scikit-learn vs TensorFlow vs PyTorch)
- Comparaison outils DataViz (Chart.js vs D3.js vs Recharts vs Plotly)

C1.3 - Solution data

- Modèle conceptuel données (MCD géospatial)
- Pipeline ETL (Extract, Transform, Load)
- Qualité données (validation, nettoyage, dédoublonnage)

Bloc 2.5 - Traitement des données massives

C2.5.1 - Collecte de données

- Intégration flux IoT (MQTT, HTTP)
- Validation données temps réel
- Gestion données manquantes et aberrantes

C2.5.2 - Traitement par lots

- Agrégations SQL (GROUP BY, WINDOW functions, CTE)
- Pandas/NumPy pour calculs complexes
- Optimisation performances (index, partitionnement, EXPLAIN)

C2.5.3 - Stockage données massives

- PostgreSQL + PostGIS
- Design schéma OLAP (star schema)
- Stratégie archivage et partitionnement

C2.5.4 - Analyse descriptive

- Statistiques (moyenne, médiane, écart-type, quartiles)
- Distributions (histogrammes, box plots)
- Corrélations spatiotemporelles

C2.5.5 - Analyse prédictive

- Modèles de régression (prédiction remplissage)
- Évaluation modèles (RMSE, MAE, R^2)
- Feature engineering (variables temporelles, spatiales)

2.2 Modules de Formation Associés

Module	Heures	Lien avec le projet
Business Intelligence	28h	Dashboards, KPIs
Big Data Cloud	35h	Architecture data
Mise en situation DATA	35h	Projet ECOTRACK
Ingénierie des données	35h	ETL, qualité données
Administration entrepôt	35h	PostgreSQL avancé
Algorithme IA	35h	ML prédictif
Maths Big Data	28h	Statistiques
DataViz	28h	Graphiques avancés
Création d'une IA	35h	Scikit-learn

Total : 294h spécialité Data + 203h tronc commun

III. PÉRIMÈTRE TECHNIQUE MASTER 1 DATA

3.1 Vue d'Ensemble (115 tâches - 70% du projet)

```
┌──────────────────────────────────────────────────────────────────────────┐
│                BACHELOR DEV-DATA (82 tâches)                              │
│  PostgreSQL simple                                                        │
│  3 graphiques basiques                                                    │
│  Export CSV                                                               │
│  Carte statique                                                           │
└──────────────────────────────────────────────────────────────────────────┘


┌──────────────────────────────────────────────────────────────────────────┐
│              MASTER 1 DATA (115 tâches = Bachelor + 33)                   │
│  PostgreSQL + PostGIS (géométries)                                        │
│  8+ types de graphiques avancés                                           │
│  Heatmap + Carte choroplèthe                                              │
```

```
│ Historique avec graphiques évolution                    │
│ Analytics coûts et ROI                                  │
│ ML basique (prédiction remplissage)                     │
│ Générateur rapports (PDF, Excel)                        │
│ Dashboards personnalisables                             │
│ Requêtes spatiales optimisées                           │
│ Pipeline ETL automatisé                                 │
└─────────────────────────────────────────────────────────┘

┌─────────────────────────────────────────────────────────┐
│          MASTER 2 DATA (164 tâches = 100%)              │
│ ML avancé (clustering, classification, deep learning)   │
│ Big Data (Spark, Kafka, streaming)                      │
│ Rapports automatisés avec email + scheduler             │
│ Dashboards temps réel avec WebSocket                    │
└─────────────────────────────────────────────────────────┘
```

3.2 Répartition par Catégorie (focus Data)

Catégorie	Tâches M1	% du total	Priorité
Infrastructure BDD	6/6	100%	MUST
PostGIS (Géospatial)	**10/10**	**100%**	**MUST **
CRUD Conteneurs (aspect data)	20/26	77%	MUST
Zones géographiques	5/5	100%	MUST
Historique remplissage	8/8	100%	MUST
Analytics avancés	**10/14**	**71%**	**MUST **
Optimisation tournées (aspect data)	10/12	83%	MUST
Gamification (leaderboard)	11/15	73%	MUST
ML prédictif	**5/6**	**83%**	**MUST **
Rapports	8/10	80%	MUST
Dashboard personnalisable	6/7	86%	MUST
Tests data	3/5	60%	MUST
Documentation	4/5	80%	MUST
TOTAL	**115/164**	**70%**	-

IV. ARCHITECTURE DATA

4.1 Architecture Data Globale

Vous devez concevoir une architecture data complète :

```
┌──────────────────────────────────────────────────────────────┐
│              SOURCES DE DONNÉES                              │
│                                                              │
│  - Capteurs IoT (MQTT)                                       │
│  - API REST (agents collecte)                                │
│  - Formulaires web (citoyens)                                │
│  - Import CSV (données historiques)                          │
└──────────────────────────────────────────────────────────────┘
                  │
                  ▼
        ┌──────────────────────────┐
        │  COUCHE ETL              │
        │                          │
        │  - Extract : Collecte    │
        │  - Transform : Nettoyage │
        │  - Load : Insertion BDD  │
        └──────────────────────────┘
                  │
                  ▼
        ┌──────────────────────────┐
        │  COUCHE STOCKAGE         │
        │  PostgreSQL + PostGIS    │
        │                          │
        │  - OLTP (transactions)   │
        │  - OLAP (analytics)      │
        └──────────────────────────┘
                  │
                  ▼
        ┌──────────────────────────┐
        │  COUCHE ANALYTICS        │
        │                          │
        │  - SQL avancé            │
        │  - Pandas/NumPy          │
        │  - Scikit-learn (ML)     │
        └──────────────────────────┘
                  │
                  ▼
        ┌──────────────────────────┐
        │  COUCHE VISUALISATION    │
        │                          │
        │  - Dashboards React      │
        │  - Cartes Leaflet        │
        │  - Rapports PDF/Excel    │
        └──────────────────────────┘
```

Séparation OLTP / OLAP :

Aspect	OLTP (Transactionnel)	OLAP (Analytique)
Tables	containers, routes, users	fill_history, aggregated_stats
Usage	Lecture/Écriture fréquente	Lecture intensive
Index	B-tree sur clés primaires	Index spatiaux (GIST) + temporels
Optimisation	Normalisation (3NF)	Dénormalisation partielle

4.2 Modèle de Données Géospatial

Vous devez concevoir un modèle avec extension PostGIS :

Entités principales à modéliser :

- `containers` : Avec colonne `location` de type GEOMETRY(Point, 4326)
- `zones` : Avec colonne `polygon` de type GEOMETRY(Polygon, 4326)
- `fill_history` : Historique temporel (partitionné par mois)
- `aggregated_daily_stats` : Statistiques pré-calculées
- `ml_predictions` : Prédictions du modèle ML

Contraintes techniques :

- Utiliser SRID 4326 (WGS84 - système GPS mondial)
- Créer des index spatiaux GIST sur les colonnes géométriques
- Créer des index B-tree sur les colonnes temporelles
- Partitionner `fill_history` par mois pour performance

Types PostGIS à utiliser :

- `GEOMETRY(Point, 4326)` : Position GPS d'un conteneur
- `GEOMETRY(Polygon, 4326)` : Frontière d'une zone
- `GEOMETRY(LineString, 4326)` : Tracé d'une tournée

V. POSTGIS ET DONNÉES GÉOSPATIALES

5.1 Module PostGIS (10 tâches) - MUST

Objectif : Maîtriser les données géospatiales

#	Tâche	Description	Critères de validation
G1	Installation PostGIS	Extension PostgreSQL	`SELECT PostGIS_Version();`
G2	Migration POINT	lat/lng → GEOMETRY	Toutes positions migrées
G3	Migration POLYGON	Zones géographiques	Tous polygones migrés
G4	Index spatiaux	GIST sur geometries	EXPLAIN montre utilisation index
G5	Requêtes ST_Distance	Distance entre points	Résultat en mètres
G6	Requêtes ST_Within	Points dans polygone	Tous conteneurs d'une zone
G7	Requêtes ST_DWithin	Rayon autour d'un point	Conteneurs dans 1km
G8	Requêtes ST_Buffer	Zone tampon	Buffer de 500m
G9	Optimisation requêtes	EXPLAIN ANALYZE	< 200ms pour 2000 conteneurs
G10	Tests performance	Benchmark	Rapport de performances

5.2 Fonctions PostGIS à Maîtriser

Vous devez apprendre et utiliser ces fonctions :

Fonction	Usage	Exemple d'utilisation
`ST_Distance()`	Calcul distance	Conteneur le plus proche
`ST_Within()`	Point dans polygone	Conteneurs d'une zone
`ST_DWithin()`	Distance < seuil	Conteneurs dans rayon
`ST_Buffer()`	Zone tampon	Zone de 500m autour
`ST_Intersects()`	Intersection géométries	Zones qui se chevauchent
`ST_Area()`	Surface	Taille zone en m²
`ST_Centroid()`	Centre géométrique	Centre d'une zone
`ST_MakePoint()`	Créer un point	Depuis lat/lng
`ST_GeomFromGeoJSON()`	Import GeoJSON	Depuis API externe

5.3 Cas d'Usage Géospatiaux à Implémenter

1. Distance entre deux conteneurs

- Input : ID de 2 conteneurs
- Output : Distance en mètres
- Utiliser : `ST_Distance(location::geography, location::geography)`

2. Conteneurs dans une zone

- Input : ID de zone
- Output : Liste des conteneurs
- Utiliser : `ST_Within(container.location, zone.polygon)`

3. Conteneurs dans un rayon

- Input : Point GPS + rayon (m)
- Output : Liste conteneurs + distances
- Utiliser : `ST_DWithin(location::geography, point::geography, rayon)`

4. Densité de conteneurs par zone

- Input : Aucun
- Output : Nb conteneurs / km² par zone
- Utiliser : `COUNT(*) / (ST_Area(polygon::geography) / 1000000)`

5. Conteneur le plus proche d'un point

- Input : Point GPS
- Output : 1 conteneur
- Utiliser : `ORDER BY ST_Distance(...) LIMIT 1`

5.4 Optimisation Performances PostGIS

Techniques à implémenter :

1. **Index spatiaux GIST** : Obligatoires sur toutes colonnes GEOMETRY
2. **Cast en GEOGRAPHY** : Pour distances précises en mètres
3. **Utiliser ST_DWithin plutôt que ST_Distance + WHERE** : Meilleure utilisation des index
4. **EXPLAIN ANALYZE** : Analyser les plans d'exécution
5. **Statistiques à jour** : `ANALYZE containers;` régulièrement

VI. ANALYTICS ET DATAVIZ AVANCÉS

6.1 Module Analytics (10 tâches) - MUST

Objectif : Créer 8+ types de visualisations avancées

#	Graphique	Type	Difficulté	Bibliothèque
A1	Évolution volume collecté	Aires empilées	Moyenne	Recharts
A2	Répartition par type	Donut	Faible	Chart.js
A3	Collectes par zone	Bar horizontal	Faible	Chart.js
A4	Distribution taux remplissage	Histogramme	Moyenne	Chart.js
A5	Évolution taux moyen	Line chart	Faible	Recharts
A6	Performance tournées	Scatter plot	Moyenne	Recharts
A7	Incidents et alertes	Timeline	Élevée	Custom/D3.js
A8	**Heatmap collectes jour×heure**	Heatmap	**Élevée**	Nivo/D3.js
A9	**Carte choroplèthe zones**	Carte choroplèthe	**Élevée**	Leaflet
A10	Analyse coûts et ROI	Mixed chart	Moyenne	Recharts

6.2 Spécifications par Graphique

A1 : Évolution Volume Collecté (Aires Empilées)

- **Données** : Volume par type de déchet par jour
- **Axes** : X = Date, Y = Volume (tonnes)
- **Séries** : 1 aire par type (verre, plastique, organique)
- **Interaction** : Tooltip au survol, légende cliquable

A2 : Répartition par Type (Donut)

- **Données** : Pourcentage par type de déchet
- **Format** : Pourcentages + valeurs absolues
- **Couleurs** : Palette cohérente (vert, bleu, orange, rouge)
- **Interaction** : Highlight au survol

A8 : Heatmap Collectes Jour × Heure

- **Axes** : X = Heure (0-23h), Y = Jour (Lun-Dim)
- **Couleur** : Intensité = nombre de collectes
- **Échelle** : Dégradé (blanc → jaune → rouge)
- **Objectif** : Identifier les créneaux de pointe

Requête SQL à construire :

- Extraire heure et jour de semaine de `completed_at`
- Grouper par jour + heure
- Compter le nombre de collectes

A9 : Carte Choroplèthe Zones

- **Données** : Densité de conteneurs par zone (conteneurs/km²)
- **Couleurs** : Dégradé (vert → jaune → orange → rouge)
- **Légende** : Échelle de couleurs avec valeurs
- **Interaction** : Popup au clic sur zone
- **Objectif** : Visualiser les zones critiques

Calculs à effectuer :

- Compter conteneurs par zone
- Calculer surface de chaque zone en km² (ST_Area)
- Calculer densité = nb / surface

6.3 Dashboard Analytics Principal

Structure attendue :

```
┌──────────────────────────────────────────────────────────────────────────┐
│ Analytics & Statistiques                                                 │
│ Période : [Date picker] Dernier mois ▼                                   │
├──────────────────────────────────────────────────────────────────────────┤
│                                                                          │
│ KPIs Principaux (6 cartes)                                               │
│ ┌──────────┐ ┌──────────┐ ┌──────────┐ ┌──────────┐                    │
│ │ Volume   │ │Collectes │ │  Taux    │ │  Coût    │                    │
│ │ 2,456t   │ │  1,234   │ │  72%     │ │45,678€   │                    │
│ │  +12%    │ │   -5%    │ │  +3%     │ │  -8%     │                    │
│ └──────────┘ └──────────┘ └──────────┘ └──────────┘                    │
│                                                                          │
│ Graphiques (Grille 2×4)                                                  │
│ ┌──────────────────────┐ ┌──────────────────────┐                      │
│ │ Évolution Volume     │ │ Répartition Type     │                      │
│ │ (Aires empilées)     │ │ (Donut)              │                      │
│ └──────────────────────┘ └──────────────────────┘                      │
│                                                                          │
│ ┌──────────────────────┐ ┌──────────────────────┐                      │
│ │ Heatmap              │ │ Distribution         │                      │
│ │ (Jour × Heure)       │ │ (Histogramme)        │                      │
│ └──────────────────────┘ └──────────────────────┘                      │
│                                                                          │
│ [Exporter PDF] [Exporter Excel] [Rapport automatique]                    │
└──────────────────────────────────────────────────────────────────────────┘
```

VII. MACHINE LEARNING BASIQUE

7.1 Module ML (5 tâches) - MUST

Objectif : Prédire le taux de remplissage futur des conteneurs

#	Tâche	Description	Critères de validation
ML1	Feature engineering	Créer variables prédictives	8+ features
ML2	Modèle régression	LinearRegression ou RandomForest	Implémenté
ML3	Entraînement	Train/test split 80/20	Modèle entraîné
ML4	Évaluation	Calcul RMSE, MAE, R^2	$R^2 > 0.65$
ML5	API prédiction	Endpoint `/predict`	Temps < 100ms

7.2 Problème à Résoudre

Question : Quel sera le taux de remplissage d'un conteneur dans 24h ?

Inputs :

- Historique des taux de remplissage
- Type de conteneur
- Position géographique (zone)
- Jour de la semaine
- Heure de la journée
- Météo (optionnel)

Output : Taux de remplissage prédit (0-100%)

7.3 Feature Engineering

Vous devez créer ces variables :

1. Features temporelles :

- `hour` : Heure de la journée (0-23)
- `day_of_week` : Jour (0=lundi, 6=dimanche)
- `day_of_month` : Jour du mois (1-31)
- `is_weekend` : 1 si samedi/dimanche, 0 sinon
- `is_peak_hour` : 1 si heure de pointe (8-9h, 17-19h)

2. Features lag (valeurs passées) :

- `fill_rate_1h_ago` : Taux il y a 1h
- `fill_rate_24h_ago` : Taux il y a 24h
- `fill_rate_7d_ago` : Taux il y a 7 jours

3. Features rolling (moyennes mobiles) :

- `fill_rate_24h_avg` : Moyenne sur 24h
- `fill_rate_7d_avg` : Moyenne sur 7 jours
- `fill_rate_change_rate` : Taux de variation

4. Features conteneur :

- `capacity` : Capacité (litres)
- `type_encoded` : Type encodé (0=verre, 1=plastique, etc.)
- `zone_density` : Densité de la zone

7.4 Algorithmes à Tester

Vous devez implémenter et comparer :

1. **Régression Linéaire** :
   - Rapide, interprétable
   - Bibliothèque : `sklearn.linear_model.LinearRegression`
2. **Random Forest Regressor** :
   - Plus précis, gère non-linéarité
   - Bibliothèque : `sklearn.ensemble.RandomForestRegressor`

Comparaison attendue :

Modèle	RMSE	MAE	R^2	Temps (ms)
Linear	?	?	?	?
Random Forest	?	?	?	?

7.5 Évaluation du Modèle

Métriques à calculer :

```
RMSE (Root Mean Squared Error) :
- Formule : √(Σ(y_pred - y_true)² / n)
- Unité : Même que la cible (%)
- Objectif : < 10%

MAE (Mean Absolute Error) :
- Formule : Σ|y_pred - y_true| / n
- Interprétation : Erreur moyenne en %
- Objectif : < 7%

R² (Coefficient de détermination) :
- Formule : 1 - (SS_res / SS_tot)
- Plage : 0 à 1 (1 = parfait)
- Objectif : > 0.65
```

Graphiques d'évaluation à produire :

- Courbe prédictions vs réalité (scatter plot)
- Distribution des erreurs (histogramme)
- Feature importance (bar chart)

7.6 API de Prédiction

Endpoint à créer : `POST /api/ml/predict`

Requête :

[Code à implémenter selon les spécifications ci-dessus] yaml Backend Data: Runtime: Python 3.11+ (recommandé pour data) Framework: FastAPI 0.104+ OU Flask 3.0+ Data Processing: - Pandas 2.0+ - NumPy 1.24+ Machine Learning: Scikit-learn 1.3+ Visualization: Matplotlib 3.7+, Seaborn 0.12+

Database:
Primary: PostgreSQL 15+
Extension: PostGIS 3.3+

Frontend DataViz:
Charts: Recharts 2.8+ OU Chart.js 4.4+
Heatmap: @nivo/heatmap OU D3.js
Maps: Leaflet 1.9+ + leaflet-choropleth

Reporting:
PDF: reportlab OU pdfkit
Excel: openpyxl OU xlsxwriter

DevOps Data:
Notebooks: Jupyter Lab / Google Colab
Testing: Pytest
ETL: Custom Python scripts
Scheduler: Cron OU Apache Airflow (optionnel)

Tools:
Data Quality: Great Expectations (optionnel)
SQL Client: DBeaver / pgAdmin

X. ORGANISATION ET MÉTHODOLOGIE

10.1 Équipes (3-4 étudiants)

Rôles spécifiques Data :
- **Data Engineer** : PostGIS, ETL, optimisations BDD
- **Data Analyst** : Analytics, dashboards, rapports
- **ML Engineer** : Modèle prédictif, feature engineering
- **Full-Stack Data** (si 4) : API, frontend DataViz

Rotation des rôles : Tous les 2 sprints

XI. LIVRABLES ET JALONS

11.1 Planning (4 mois - 16 semaines)

MOIS 1 : Fondations Data (Semaines 1-4)

Semaines 1-2 : Modélisation
- Installation et configuration PostGIS
- Conception modèle géospatial (MCD/MLD)
- Migration données vers GEOMETRY
- Création index spatiaux

Livrable 1 (S2) : Modèle Data (20 points)
- MCD/MLD avec types PostGIS
- Script migration
- Documentation dictionnaire de données

Semaines 3-4 : Pipeline ETL
- Développement pipeline ETL
- Tests qualité données
- API analytics basique (3 endpoints)

Livrable 2 (S4) : Pipeline ETL (20 points)
- Script ETL fonctionnel
- Rapport qualité données
- Documentation pipeline

MOIS 2 : Analytics Avancés (Semaines 5-8)

Semaines 5-8
- Implémentation 8 types de graphiques
- Heatmap jour × heure
- Carte choroplèthe zones
- Dashboards interactifs
- Historique avec graphiques

Livrable 3 (S8) : Dashboards Analytics (35 points)
- 8 graphiques fonctionnels
- Heatmap + choroplèthe opérationnels
- Dashboard responsive
- Documentation utilisation

MOIS 3 : Machine Learning et Rapports (Semaines 9-12)

Semaines 9-10 : ML
- Feature engineering
- Implémentation 2 modèles
- Évaluation et comparaison
- Notebook Jupyter avec analyses

Semaines 11-12 : Rapports
- Générateur rapports PDF/Excel
- Analyse coûts et ROI
- Tests automatisés

Livrable 4 (S12) : ML + Rapports (35 points)
- Modèle ML ($R^2 > 0.65$)
- API prédiction fonctionnelle
- Générateur rapports
- Notebook analyses

MOIS 4 : Finalisation (Semaines 13-16)

Semaines 13-16
- Optimisations performances
- Tests qualité données
- Documentation complète (DCT Data)
- Préparation soutenance

Livrable Final (S16) : Projet Complet (130 points)

XII. CRITÈRES D'ÉVALUATION

12.1 Grille Master 1 Data (130 points)

1. Technique Data (45 points)

Critère	Points	Détail
Modèle PostGIS	10	Types géométriques, SRID correct
Requêtes spatiales	10	5+ fonctions ST_* maîtrisées
Analytics (8+ graphiques)	10	Visualisations pertinentes
Pipeline ETL	8	Automatisé, qualité données
Performances	7	Requêtes < 200ms

2. Machine Learning (20 points)

Critère	Points	Détail
Feature engineering	5	8+ features pertinentes
Modèle ($R^2 > 0.65$)	8	Performance validée
Évaluation	4	RMSE, MAE, R^2, graphiques
API prédiction	3	Endpoint fonctionnel

3. DataViz (20 points)

Critère	Points	Détail
Heatmap	5	Jour × Heure fonctionnelle
Choroplèthe	5	Carte densité zones
Dashboards	7	8 graphiques + interactivité
UX/UI	3	Design cohérent

4. Documentation (15 points)

Critère	Points	Détail
DCT Data	8	25-30 pages, modèle, algorithmes
Dictionnaire données	4	Toutes tables documentées
Notebooks Jupyter	3	Analyses exploratoires

5. Présentation (20 points)

Critère	Points	Détail

Démo analytics	10	Dashboards + graphiques
Démo ML	5	Prédictions en temps réel
Réponses questions	5	Maîtrise concepts data

6. Qualité & Tests (10 points)

Critère	Points	Détail
Tests Python	5	Pytest, couverture >50%
Qualité données	5	ETL sans erreurs

12.2 Critères de Validation

Validation du projet Master 1 Data :
- Note globale ≥ 78/130 (60%)
- Technique Data ≥ 27/45 (60%)
- ML ≥ 12/20 (60%)
- PostGIS opérationnel
- Modèle ML avec $R^2 > 0.65$
- 8 graphiques fonctionnels

XIII. RESSOURCES ET APPRENTISSAGE

A. Documentation Officielle

PostGIS
- [PostGIS Documentation](https://postgis.net/documentation/)
- [PostGIS in Action (book)](https://www.manning.com/books/postgis-in-action)
- [Boundless PostGIS Tutorials](https://www.boundlessgeo.com/resources/)

Data Science
- [Pandas User Guide](https://pandas.pydata.org/docs/user_guide/)
- [NumPy Documentation](https://numpy.org/doc/)
- [Scikit-learn Tutorials](https://scikit-learn.org/stable/tutorial/)

Visualisation
- [Recharts Examples](https://recharts.org/en-US/examples)
- [Chart.js Documentation](https://www.chartjs.org/docs/)
- [D3.js Gallery](https://observablehq.com/@d3/gallery)
- [Leaflet Tutorials](https://leafletjs.com/examples.html)

B. Cours et Tutoriels

SQL Spatial
- [PostGIS Tutorial](https://postgis.net/workshops/postgis-intro/)
- [Spatial SQL with PostGIS](https://www.crunchydata.com/blog/spatial-sql-with-postgis)

Machine Learning
- [Coursera - Machine Learning by Andrew Ng](https://www.coursera.org/learn/machine-learning)
- [Kaggle Learn - Intro to ML](https://www.kaggle.com/learn/intro-to-machine-learning)
- [Fast.ai - Practical Deep Learning](https://www.fast.ai/)

Data Engineering
- [DataCamp - Data Engineering Track](https://www.datacamp.com/tracks/data-engineer-python)
- [Awesome Data Engineering](https://github.com/igorbarinov/awesome-data-engineering)

C. Livres Recommandés

Livre	Auteur	Sujet
Python for Data Analysis	Wes McKinney	Pandas, NumPy
Hands-On Machine Learning	Aurélien Géron	Scikit-learn, TensorFlow
Designing Data-Intensive Applications	Martin Kleppmann	Architecture data
The Data Warehouse Toolkit	Ralph Kimball	Modélisation OLAP

D. Checklist Pré-Soutenance

3 jours avant :
- [ ] Application déployée avec dashboards accessibles
- [ ] Modèle ML entraîné et API fonctionnelle
- [ ] DCT Data complet (25-30 pages)
- [ ] Notebooks Jupyter exportés en PDF
- [ ] Dictionnaire de données à jour
- [ ] Tests qualité données validés

Jour J :
- [ ] Démonstration dashboards préparée
- [ ] Exemple prédiction ML en direct
- [ ] Slides de présentation (20-25)
- [ ] Données de démo réalistes

E. FAQ

Q : Doit-on utiliser Python obligatoirement ?
R : Fortement recommandé pour data. Node.js accepté mais moins adapté.

Q : Peut-on utiliser des bibliothèques ML pré-entraînées ?
R : Non, vous devez entraîner votre propre modèle. C'est l'objectif pédagogique.

Q : Le modèle ML doit-il être très précis ?
R : $R^2 > 0.65$ est le seuil minimum. Viser 0.75-0.80 pour l'excellence.

Q : Combien de temps pour le projet ?
R : 15-20h/semaine (cours + autonome).

CONCLUSION

Vous allez devenir des **Data Engineers** et **Data Scientists** compétents en maîtrisant :

PostGIS : Données géospatiales, requêtes spatiales optimisées
Analytics : 8+ visualisations avancées (heatmap, choroplèthe)
Machine Learning : Modèles prédictifs, évaluation rigoureuse
ETL : Pipelines automatisés, qualité des données
DataViz : Dashboards interactifs professionnels

Réussite Data = Maîtrise SQL spatial
+ Analytics pertinents
+ ML rigoureux
+ Documentation complète
+ Curiosité pour les données

Version : 3.0 (Pédagogique)
Date : Novembre 2025